Casa Óga — Formulación del tablero de riesgo de clientes

Materia 82.21 — Factibilidad de Proyectos Data Driven
Entregables 1 a 3 — Grupo 2 — Anexo de fórmulas, v2.4

Sebastián Caules	64331
Tomás Ferreccio	64934
Matías Sola	64322
Francisco Cattaneo	64900
Juan Manuel Rilo	64037

27/10/2026 (v1.0: 01/09/2026)

Este documento fija la notación y la trazabilidad de las fórmulas del tablero de riesgo de clientes de Casa Óga. Cada fórmula indica la línea de código que la implementa y el valor que produce sobre el corte de referencia, 31/12/2025. El tablero del Entregable 1 tiene el mes de corte móvil (25 cortes): por eso cada fórmula lleva el parámetro t explícito en la notación, nunca implícito. El pipeline recalcula todo desde cero en cada corte, usando solo transacciones con `fecha` $\leq t$ (`pipeline/features.py:69`). Los valores citados corresponden a la corrida de `pipeline/build.py`, que verificó 134 anclas del contrato de datos (`pipeline/CONTRACT.md` sección 5) antes de escribir el payload. Desde la v2.3, las secciones 10, 11 y 13 definen también los términos y las cifras derivadas que usan las Partes A a D del Entregable 3; cada una dice su población y su corte, que no siempre es el 31/12/2025. La v2.4 suma la evaluación en test de la Parte D del Entregable 3 (subsecciones 10.6 a 10.8).

Índice

1. Tabla de símbolos **3**

2. Limpieza de transacciones **4**

3. Métricas por cliente **5**
3.1. Facturación acumulada . . . 5
3.2. Recency . . . 5
3.3. Gap mediano propio . . . 5
3.4. Elegibilidad . . . 5
3.5. Riesgo . . . 6
3.6. Anualización del gasto . . . 6
3.7. Quintil de facturación . . . 7
3.8. Región dominante . . . 7
3.9. Categoría dominante . . . 7

4. Segmentación RFM **7**
4.1. Scores R, F, M . . . 7
4.2. Reglas de segmento . . . 8

5. Tabla de contingencia **8**
5.1. Clave empaquetada k . . . 8
5.2. Celdas agregadas . . . 9

6. Exposición agregada **9**
6.1. Descomposición por dimensión 9

7. Indicadores de la Parte D, sección 2.1 **9**
7.1. Tasa de recompra a 90 días 10
7.2. Ingreso anual en riesgo (exposición) 10
7.3. Clientes en riesgo 10
7.4. Riesgo en el quintil de mayor valor (Q5) 10
7.5. Cobertura de contacto 11
7.6. Cobertura ejecutable de la lista 11
7.7. Compra a 7 días sobre contactados 11

8. Exposición por ventana de 90 días **12**

9. Poder discriminante de las features **12**

10. Anticipación: qué confirma la regla y qué promete el modelo **13**
10.1. Días para cruzar el umbral y cercanía 14
10.2. Regla del umbral 14
10.3. Precisión de la lista mensual 14
10.4. Meta del criterio de éxito 1 15
10.5. Partición por corte y embargo 15
10.6. Evaluación en test 16
10.7. Diferencia entre dos listas e intervalo por bootstrap de clientes 16
10.8. Criterio para reemplazar la regla por un modelo 17

11. Experimento propuesto y efecto mínimo detectable **17**
11.1. Umbral de producción del piloto 18

12. Limitación: la caída del extracto en 2025 **18**

13. Supuesto: la exposición no es recupero **18**
13.1. Tasa de éxito de la acción 19
13.2. Valor de cada celda de la matriz de confusión 19
13.3. Valor anual de la lista y tasa de éxito de equilibrio 20
13.4. Valor de un punto de precisión 20
13.5. Costo por cliente que vuelve 20

14. Supuesto: el proxy de churn no es churn **21**

1. Tabla de símbolos

Un símbolo tiene un único significado en todo el documento. La tabla cubre las 25 fechas de corte, los campos por cliente y los agregados de la tabla de contingencia, y desde la v2.3 los símbolos del Entregable 3 (la v2.4 suma los de la evaluación en test). Los escalares s, r, m, d y c son los de la Parte B del Entregable 3; el ticket medio, que esa parte escribe t, va acá como $\bar{t}$ para no confundirlo con el corte.

Símbolo	Significado
t	Corte: fin de mes usado como parámetro móvil. 25 valores, 2023-12-31 a 2025-12-31 (`pipeline/loader.py:20-22`). Corte de referencia de este documento: 2025-12-31.
i	Índice de un cliente individual (`id_cliente`).
$F_i(t)$	Facturación acumulada del cliente i con `fecha` $\leq t$: suma de `monto_neto`.
$n_i(t)$	Cantidad de compras del cliente i hasta t.
$p_i(t)$	Fecha de la primera compra de i hasta t.
$u_i(t)$	Fecha de la última compra de i hasta t.
$\rho_i(t)$	Recency: días entre $u_i(t)$ y t.
$\gamma_i(t)$	Gap mediano propio: mediana de los días entre compras consecutivas de i hasta t.
$E_i(t)$	Indicador de elegibilidad, 1 si $n_i(t) \geq 3$, si no 0.
$\theta_i(t)$	Umbral de riesgo del cliente i, en días: $\max(90,\ 1{,}5\,\gamma_i(t))$.
$B_i(t)$	Indicador de riesgo (proxy operativo de *churn*), 1 si i está en riesgo, si no 0.
$A_i(t)$	Años de historia del cliente i: $(t - p_i(t))/365{,}25$.
$\hat{F}_i(t)$	Facturación anualizada del cliente i.
$Q_i(t)$	Quintil de facturación de i, 1 a 5.
$\mathrm{reg}_i(t)$	Región donde i concentra su gasto en tienda física, o `Solo online`.
$\mathrm{cat}_i(t)$	Categoría donde i concentra su gasto.
$\mathcal{R}_i(t), \mathcal{F}_i(t), \mathcal{M}_i(t)$	Scores RFM de i: quintiles (1 a 5) de recency, frecuencia (cantidad de compras) y monto (facturación).
$S_i(t)$	Segmento RFM asignado a i: una de siete etiquetas excluyentes.
$r_i(t), c_i(t), s_i(t)$	Índices 0-based de región (0 a 5), categoría (0 a 6) y segmento RFM (0 a 6) de un cliente, usados para construir k.
q	Quintil de facturación, 1 a 5, usado (como $q-1$) para construir k.
k	Clave empaquetada de una celda de la tabla de contingencia región×categoría×RFM×quintil.
$n_k(t)$	Clientes de la celda k en el corte t.
$nr_k(t)$	Clientes en riesgo de la celda k.
$ne_k(t)$	Clientes elegibles de la celda k.
$f_k(t)$	Facturación histórica total de la celda k.
$fr_k(t)$	Facturación histórica de los clientes en riesgo de la celda k.
$a_k(t)$	Facturación anualizada total de la celda k.
$ar_k(t)$	Facturación anualizada de los clientes en riesgo de la celda k (exposición de la celda).
$X(t)$	Exposición agregada: suma de $\hat{F}_i(t)$ sobre los clientes en riesgo.
T	Corte de predicción del dataset de entrenamiento: fin de mes, del 31/01/2023 al 30/09/2025.

Símbolo	Significado
$Y_i(T)$	Target del modelo: 1 si el cliente cruza su umbral en $(T,\, T+90]$ (sección 10).
$h_i(T)$	Días que le faltan al cliente i para cruzar su umbral en T.
$\mathrm{cerca}_i(T)$	Indicador de cercanía al umbral, 1 si $h_i(T) < 90$.
$L(T)$, $L^c(T)$	Lista de 500 del corte T, y la misma lista armada solo con clientes contactables.
P_{500}, M_1	Precisión de la lista de 500 y meta del criterio de éxito 1, en aciertos por mes.
N_1, N_2, δ	Tamaños de dos grupos del piloto y efecto mínimo detectable entre ellos.
s, r	Tasa de éxito de la acción y parte de los falsos positivos que usa el descuento.
m, d, $\bar{t}$, c	Margen que vuelve con un cliente, descuento, ticket medio y costo de la acción.
v_{VP}, v_{FP}	Valor esperado de un verdadero y de un falso positivo, frente a no hacer nada.
V, s^*, Δ	Valor anual de la lista, tasa de éxito de equilibrio y diferencia de compra que mide el piloto.
$\mathcal{C}$, $V_{\mathcal{C}}$	Cortes evaluados (3 en validación, 5 en test) y valor de la lista en esos cortes llevado a un año.
P^c, R^c, $\mathrm{F1}^c$	Precisión, recall y F1 de la lista de 500 contactables, sumadas sobre los cortes de $\mathcal{C}$.
$\pi_i(T)$, AUC^c	Puntaje con que se ordena la lista, y AUC-ROC de ese puntaje sobre todas las filas contactables.
D, $D^{(b)}$	Precisión del modelo menos la de la regla en la misma lista, y su valor en la réplica b del bootstrap.
C_{extra}, a^*	Lo que el modelo agrega al costo del año 1 y aciertos de más por mes que lo pagan.

2. Limpieza de transacciones

La limpieza se aplica en orden fijo sobre `Transacciones_clientes.csv` y cada etapa reporta su propio conteo: los cuatro números viajan en el payload bajo `stage_counts`, no son un registro de depuración.

$$\mathrm{tx}_{\text{crudo}} \xrightarrow{\texttt{drop_duplicates()}} \mathrm{tx}_{\text{dedupe}} \xrightarrow{\texttt{id_cliente no nulo}} \mathrm{tx}_{\text{identificado}} \xrightarrow{\texttt{monto_neto}>0} \mathrm{tx}_{\text{limpio}} \qquad (1)$$

Etapa	Regla	Conteo
crudo	lectura tal cual	50.250
dedupe	`drop_duplicates()` de fila completa	50.000
identificado	`id_cliente` no nulo	27.606
monto $>$ 0	`monto_neto` $>$ 0	27.276

Implementación: `pipeline/loader.py:35 (dedupe), :36 (identificado), :37 (monto_neto` >0`); los mismos filtros se repiten en stage_counts, pipeline/loader.py:54-56.`
Valor al corte 31/12/2025: 50.250 $\rightarrow$ 50.000 $\rightarrow$ 27.606 $\rightarrow$ 27.276, los cuatro chequeados como anclas en `pipeline/build.py:213-219`.

Dos notas de calidad que el pipeline declara en vez de corregir en silencio: las 250 filas que saca el dedupe son exactamente las de `id_transaccion` duplicado (`dup_ids_crudo` = 250, `dup_ids_post` = 0); y los montos ≤ 0 son 613 en crudo y 608 tras el dedupe, todos estrictamente negativos, ninguno en cero. El canal se normaliza de 4 etiquetas a 2 (`Tienda`/`tienda` $\rightarrow$ `fisico`, `Online`/`E-commerce` $\rightarrow$ `online`), `pipeline/loader.py:12-17,40`. No se deflacta por IPC. Casa Óga declaró que `monto_neto` está en pesos corrientes del día de la venta (relevamiento, envío 55), pero el extracto no tiene deriva de precios (precio unitario implícito $-7{,}6\,\%$ de 2022 a 2025, plano en las siete categorías; medición del 27/08/2026): no hay inflación en el dato que corregir. Todo importe de este documento es en pesos del extracto tal como llegan, y la pregunta de si el extracto se normalizó al exportarlo vuelve al negocio en el Entregable 2.

3. Métricas por cliente

3.1. Facturación acumulada

$$F_i(t) = \sum_{\substack{j:\ \text{cliente}(j)=i \\ \text{fecha}_j \leq t}} \text{monto_neto}_j \tag{2}$$

Implementación: `pipeline/features.py:71-72 (agg.facturacion, groupby("id_cliente").sum())`.
Valor al corte 31/12/2025: facturación de toda la base $=$ ARS 550,2 M; facturación de los clientes en riesgo $=$ ARS 262,8 M.

3.2. Recency

$$\rho_i(t) = t - u_i(t) \quad \text{(días)} \tag{3}$$

Implementación: `pipeline/features.py:78`.
Valor al corte 31/12/2025: mediana 277 días sobre los 5.978 clientes con compra válida (rango 2 a 1.438 días). Ejemplo `CLI00002`: $\rho = 73$ días.

3.3. Gap mediano propio

$$\gamma_i(t) = \text{mediana}\big(\{u_{i,m+1} - u_{i,m}\}_{m=1}^{n_i(t)-1}\big) \quad \text{(días entre compras consecutivas)} \tag{4}$$

Implementación: `pipeline/features.py:18-23 (_gap_mediano_por_cliente), :79 (asignación)`.
Valor al corte 31/12/2025: mediana de la base 163 días, sobre los 5.663 clientes con dos compras o más. Ejemplo `CLI00002`: $\gamma = 57$ días; `CLI00004`: $\gamma = 120{,}5$ días.

Los 315 clientes con una sola compra no tienen $\gamma_i(t)$ definido (diferencia sobre una serie de un solo punto). Verificado: esos 315 coinciden exactamente con los clientes de $n_i(t) = 1$, y ninguno es elegible, así que el valor indefinido nunca llega a la regla de riesgo (sección 3.5).

3.4. Elegibilidad

$$E_i(t) = \mathbf{1}\big[n_i(t) \geq 3\big] \tag{5}$$

Implementación: `pipeline/features.py:81`.
Valor al corte 31/12/2025: 4.940 elegibles de 5.978 clientes (82,6 %).

3.5. Riesgo

$$\theta_i(t) = \max\big(90,\ 1{,}5\,\gamma_i(t)\big) \quad \text{(días)} \tag{6}$$

$$B_i(t) = E_i(t) \wedge \big[\rho_i(t) > \theta_i(t)\big] \tag{7}$$

Implementación: `pipeline/features.py:82-84`.
Valor al corte 31/12/2025: 2.452 clientes en riesgo de 5.978 (41,0 %).

Un cliente no elegible nunca puede estar en riesgo, aunque lleve años sin comprar: la ecuación (7) exige $E_i(t) = 1$ antes de evaluar el umbral. La sección 14 desarrolla la consecuencia aritmética de esta exigencia.

Dos ejemplos concretos del umbral $\theta_i(t)$, verificados sobre el corte de referencia: `CLI00002` tiene 8 compras y $\gamma = 57$, así que $\theta = \max(90,\ 85{,}5) = 90$ (domina el piso) y con $\rho = 73 < 90$ no está en riesgo. `CLI00004` tiene 5 compras y $\gamma = 120{,}5$, así que $\theta = \max(90,\ 180{,}75) = 180{,}75$ (domina $1{,}5\gamma$) y con $\rho = 287 > 180{,}75$ sí está en riesgo. Entre los 4.940 elegibles, el piso de 90 días domina en 351 casos y $1{,}5\gamma$ domina en los 4.589 restantes.

3.6. Anualización del gasto

$$A_i(t) = \frac{t - p_i(t)}{365{,}25} \quad \text{(años)} \tag{8}$$

$$\hat{F}_i(t) = \begin{cases} F_i(t) & \text{si } A_i(t) = 0 \\ F_i(t)\ /\ A_i(t) & \text{si } A_i(t) > 0 \end{cases} \tag{9}$$

Implementación: `pipeline/features.py:86-87`.
Valor al corte 31/12/2025: base anualizada total = ARS 204,6 M; exposición (anualizado de los en riesgo) = ARS 94,9 M.

Supuesto. $A_i(t)$ se mide desde la *primera* compra hasta el corte, no hasta la última. Es el punto no obvio del caso: la alternativa intuitiva sería medir la ventana de compras observada, de $p_i(t)$ a $u_i(t)$. Esa alternativa castiga exactamente a los clientes que interesa medir bien: un cliente que compró seguido durante seis meses y después dejó de comprar tendría una ventana corta (0,5 años) sobre una facturación ya alta, y su gasto anualizado se dispararía por el solo hecho de estar inactivo. Usar t (el corte, no $u_i(t)$) como fin de la ventana evita ese sesgo: el denominador sigue creciendo mes a mes aunque el cliente no vuelva a comprar, así que la inactividad no infla la proyección anual. La contrapartida es la opuesta: un cliente nuevo con muy poca historia (denominador chico) puede anualizar de más. Se mide en vez de corregir en silencio: 111 clientes (1,9 % de la base) tienen menos de un año de historia al corte de referencia, contra 2.661 (52,0 %) en el primer corte de la serie (2023-12-31), cuando casi toda la base era reciente. Ninguno de los 111 con historia corta del corte de referencia está en riesgo antes de los 0,605 años de antigüedad (el mínimo de $A_i(t)$ entre los $B_i(t) = 1$), así que el sesgo de historia corta no contamina la exposición $X(t)$ de la sección 6, sólo infla algunos términos de la base anualizada total que no están en riesgo.

El comentario original en `pipeline/build.py:74-75` declara para este mismo corte "31 clientes y 2,8 % de la base": ese número no reprodujo al correr el código (`pipeline/build.py:76-77`, `corta = anios < 1.0`, sobre `facts` del corte 2025-12-31 da 111 clientes). El valor que viaja en el payload bajo `exposicion_por_corte[-1].clientes_historia_corta` es 111, y es el que se reporta acá; el comentario del código quedó desactualizado y no se fuerza para que coincida.

3.7. Quintil de facturación

$$Q_i(t) = \mathrm{qcut}_5\big(F_i(t)\big) \in \{1, \dots, 5\} \tag{10}$$

Implementación: `pipeline/features.py:89 (pd.qcut(facturacion, 5, ...))`.
Valor al corte 31/12/2025: ver tabla 5 (sección 14). Rangos de facturación: Q1 de ARS 500 a 42.953; Q5 de ARS 135.867 a 415.135.

3.8. Región dominante

$$\mathrm{reg}_i(t) = \begin{cases} \arg\max_{r} \sum_{\substack{j:\ \text{región}(j)=r \\ \text{canal}(j)=\text{físico},\ \text{fecha}_j \le t}} \text{monto_neto}_j & \text{si } i \text{ tiene compra en tienda física} \\ \texttt{Solo online} & \text{si no} \end{cases} \tag{11}$$

Implementación: `pipeline/features.py:26-32 (_region_dominante); asignación en la línea 91`.
Valor al corte 31/12/2025: 317 clientes `Solo online` al 31/12/2025 (5,3 % de la base). Ejemplo `CLI00002`: `Centro`.

3.9. Categoría dominante

$$\mathrm{cat}_i(t) = \arg\max_{c} \sum_{\substack{j:\ \text{categoría}(j)=c \\ \text{fecha}_j \le t}} \text{monto_neto}_j \tag{12}$$

Implementación: `pipeline/features.py:35-38 (_categoria_dominante), :92 (asignación)`.
Valor al corte 31/12/2025: Muebles concentra la mayor cantidad de clientes (1.897, 44,4 % en riesgo); Baño la menor (166, 28,9 % en riesgo). Ejemplo `CLI00002`: `Muebles`.

4. Segmentación RFM

4.1. Scores R, F, M

$$\mathcal{R}_i(t) = \mathrm{qcut}_5\Big(\mathrm{rank}^{\downarrow}_{\text{first}}\big(\rho_i(t)\big)\Big) \tag{13}$$

$$\mathcal{F}_i(t) = \mathrm{qcut}_5\Big(\mathrm{rank}^{\uparrow}_{\text{first}}\big(n_i(t)\big)\Big) \tag{14}$$

$$\mathcal{M}_i(t) = \mathrm{qcut}_5\Big(\mathrm{rank}^{\uparrow}_{\text{first}}\big(F_i(t)\big)\Big) \tag{15}$$

donde $\mathrm{rank}^{\uparrow}_{\text{first}}$ ordena de menor a mayor y $\mathrm{rank}^{\downarrow}_{\text{first}}$ de mayor a menor, empates resueltos por orden de aparición (`method="first"`), y qcut_5 reparte esos rangos en 5 bloques del mismo tamaño, etiquetados 1 a 5 en el orden del ranking. El score $\mathcal{R}_i(t)$ queda invertido respecto de $\rho_i(t)$: recency baja (compró hace poco) da score alto, como pide el contrato.
Implementación: `pipeline/features.py:41-45 (_qcut_rank_5), :94-96 (asignación de R, F, M)`.
Valor al corte 31/12/2025: sin valor único por ser cálculo por cliente. Cada score reparte 1.195 o 1.196 clientes por quintil, por construcción de `qcut`.

4.2. Reglas de segmento

Siete reglas excluyentes, evaluadas en este orden; la primera que aplica gana y saca al cliente de la evaluación de las siguientes (`pipeline/features.py:48-65`, variable `aun_sin_asignar`):

1. `Campeones`: $\mathcal{R}_i(t) \geq 4 \wedge \mathcal{F}_i(t) \geq 4 \wedge \mathcal{M}_i(t) \geq 4$
2. `En riesgo`: $\mathcal{R}_i(t) \leq 2 \wedge \mathcal{F}_i(t) \geq 3$
3. `Leales`: $\mathcal{R}_i(t) \geq 3 \wedge \mathcal{F}_i(t) \geq 4$
4. `Hibernando`: $\mathcal{R}_i(t) \leq 2 \wedge \mathcal{F}_i(t) \leq 2$
5. `Nuevos`: $\mathcal{R}_i(t) \geq 4 \wedge n_i(t) = 1$ (conteo literal de compras, no el score $\mathcal{F}$)
6. `Potenciales`: $\mathcal{R}_i(t) \geq 4 \wedge \mathcal{F}_i(t) \leq 2$
7. `Perdidos`: el resto

Implementación: `pipeline/features.py:48-65 (_segmento_rfm), :98 (asignación de` $S_i(t)$`).`
Valor al corte 31/12/2025: ver tabla 2.

Segmento $S_i(t)$	Clientes
Campeones	1.014
En riesgo	1.018
Leales	820
Hibernando	1.373
Nuevos	34
Potenciales	591
Perdidos	1.128
Total	5.978

Cuadro 2: Segmentos RFM al corte de referencia. Coincide exacto con la nota de `pipeline/CONTRACT.md` sección 3 (verificado por corrida propia).

Por construcción, la regla `Nuevos` exige $n_i(t) = 1$, que nunca cumple $E_i(t) = 1$ (la elegibilidad pide $n_i(t) \geq 3$): los 34 clientes `Nuevos` tienen 0 elegibles y 0 en riesgo, verificado sobre el corte de referencia.

5. Tabla de contingencia

5.1. Clave empaquetada k

Con $|C| = 7$ categorías, $|S| = 7$ segmentos RFM y $|Q| = 5$ quintiles, la celda de un cliente se codifica en base mixta:

$$k(i,t) = \big((r_i(t) \cdot 7 + c_i(t)) \cdot 7 + s_i(t)\big) \cdot 5 + (q_i(t) - 1) \tag{16}$$

donde $r_i(t), c_i(t), s_i(t)$ son los índices 0-based de $\mathrm{reg}_i(t)$, $\mathrm{cat}_i(t)$ y $S_i(t)$ en las listas fijas del contrato, y $q_i(t) = Q_i(t)$. Es una codificación posicional de base mixta (como convertir un número de varios dígitos, cada uno con su propia base): región no lleva módulo por ser el dígito más significativo, categoría y segmento usan base 7, quintil usa base 5. El espacio total es $6 \times 7 \times 7 \times 5 = 1.470$ combinaciones posibles, k entre 0 y 1.469.
Implementación: `pipeline/features.py:104-109 (contingency, línea 109 la fórmula de` k`).`

Valor al corte 31/12/2025: ejemplo a mano, cliente `CLI00002`: región `Centro` ($r = 1$), categoría `Muebles` ($c = 4$), segmento `Campeones` ($s = 0$), quintil 5 ($q = 5$). $k = ((1 \cdot 7 + 4) \cdot 7 + 0) \cdot 5 + (5 - 1) = 389$, verificado contra la salida real de `contingency()`. La primera celda ocupada de la tabla ordenada por k es $k = 3$ (región `AMBA`, categoría `Baño`, segmento `Campeones`, quintil 4), con 2 clientes.

5.2. Celdas agregadas

Por cada celda k ocupada en el corte t, seis enteros:

$$n_k(t) = \sum_{i:\, k(i,t)=k} 1, \quad nr_k(t) = \sum_{i:\, k(i,t)=k} B_i(t), \quad ne_k(t) = \sum_{i:\, k(i,t)=k} E_i(t) \tag{17}$$

$$f_k(t) = \sum_{i:\, k(i,t)=k} F_i(t), \qquad fr_k(t) = \sum_{i:\, k(i,t)=k} B_i(t) \cdot F_i(t) \tag{18}$$

$$a_k(t) = \sum_{i:\, k(i,t)=k} \hat{F}_i(t), \qquad ar_k(t) = \sum_{i:\, k(i,t)=k} B_i(t) \cdot \hat{F}_i(t) \tag{19}$$

Implementación: `pipeline/features.py:111-125 (construcción de la tabla y groupby("k").sum()).`
Valor al corte 31/12/2025: 664 celdas ocupadas de 1.470 posibles (45,2 %) al corte de referencia. Reconciliación exacta: $\sum_k n_k(t) = 5.978$, $\sum_k nr_k(t) = 2.452$, $\sum_k ar_k(t) = 94.925.989$ (ARS 94,9 M), igual a $X(t)$ de la sección 6. Toda combinación de filtros del tablero es una suma de estas celdas: el navegador no recalcula riesgo, recency, quintiles ni RFM.

6. Exposición agregada

$$X(t) = \sum_{i:\ B_i(t)=1} \hat{F}_i(t) \ = \ \sum_k ar_k(t) \tag{20}$$

Implementación: `pipeline/build.py:185. La igualdad con` $\sum_k ar_k(t)$ `es la que usa pipeline/pack.py:13-16 para derivar la serie exposicion_por_corte: suma ar de cada contingencia y no vuelve a tocar facts.`
Valor al corte 31/12/2025: $X(31/12/2025) =$ ARS 94.925.989 ($\approx$ ARS 94,9 M).

6.1. Descomposición por dimensión

$$X(t) = \sum_r X_r(t) = \sum_c X_c(t) = \sum_s X_s(t) = \sum_q X_q(t) \tag{21}$$

$$X_d(t) = \sum_{i:\, B_i(t)=1,\ d_i(t)=d} \hat{F}_i(t) \tag{22}$$

Implementación: `misma agregación de la ecuación (20), agrupada por dimensión en vez de sumada entera. No hay función separada en el pipeline: es un groupby sobre los clientes en riesgo de facts.`
Valor al corte 31/12/2025: ver tabla 3. Las cuatro descomposiciones cierran contra ARS 94,9 M dentro del redondeo de un decimal.

7. Indicadores de la Parte D, sección 2.1

Los siete indicadores de la Parte D sección 2.1 se trazan acá contra su implementación, uno por subsección: recompra, exposición, clientes en riesgo, riesgo en Q5, cobertura de contacto, cobertura ejecutable y compra a 7 días.

Región	ARS M	Categoría	ARS M	Quintil	ARS M
AMBA	40,5	Muebles	45,4	Q1	2,2
Centro	19,7	Decoración	18,9	Q2	11,4
NOA	16,1	Iluminación	13,0	Q3	17,8
Cuyo	15,0	Textil hogar	10,3	Q4	24,8
Patagonia	2,5	Cocina y mesa	5,0	Q5	38,7
Solo online	1,2	Organización	1,3		
		Baño	1,1		

Cuadro 3: Exposición $X(t)$ descompuesta por región, categoría y quintil (RFM en el texto: `En riesgo` 36,0 M, `Leales` 21,3 M, `Campeones` 15,5 M, `Hibernando` 12,3 M, `Perdidos` 8,7 M, `Potenciales` 1,1 M, `Nuevos` 0). El quintil 5 solo concentra el 40,8 % de la exposición total pese a no ser mayoría de clientes en riesgo: es el que más factura, no el que más gente en riesgo tiene.

7.1. Tasa de recompra a 90 días

$$\tau_q(t) = \frac{\left|\{i \in \text{clientes con última compra en el trimestre } q : \exists \text{ compra en } (u_{i,q},\ u_{i,q}+90]\}\right|}{\left|\{i : \text{ última compra de } i \text{ en el trimestre } q\}\right|} \tag{23}$$

Un trimestre solo entra en el cálculo si su cierre más 90 días cae dentro del horizonte de datos disponible; si no, τ_q queda indefinido en vez de calcularse sobre una muestra sesgada de clientes con última compra temprana en el trimestre.
Implementación: `pipeline/series.py:12-90 (recompra_trimestral). Gate de observabilidad: líneas 44-59. Conteo de retorno: líneas 61-71.`
Valor al corte 31/12/2025: 2025Q3 (último trimestre observable con horizonte al 31/12/2025): $\tau = 8{,}5\,\%$ ($n =$ 1.330 clientes calculables), contra la meta de 10-11 % y la referencia de 8-9 % que estimó el negocio en el relevamiento (envío 3, “un nivel base cercano al 8-9 %”; no es una línea base medida: la serie estuvo entre 16 % y 19 % de 2023Q1 a 2025Q1) (`pipeline/build.py` meta, `meta_recompra/base_recompra`). Pico de la serie: 2024Q2 con 19,0 %.

7.2. Ingreso anual en riesgo (exposición)

Ya definido en la ecuación (20).
Implementación: `pipeline/build.py:185.`
Valor al corte 31/12/2025: ARS 94,9 M.

7.3. Clientes en riesgo

Ya definido en la ecuación (7).
Implementación: `pipeline/features.py:82-84.`
Valor al corte 31/12/2025: 2.452 de 5.978 (41,0 %).

7.4. Riesgo en el quintil de mayor valor (Q5)

$$\%\text{riesgo}_{Q5}(t) = \frac{\left|\{i :\ Q_i(t) = 5,\ B_i(t) = 1\}\right|}{\left|\{i :\ Q_i(t) = 5\}\right|} \times 100 \tag{24}$$

Implementación: `pipeline/build.py:187,210. Agrupa facts por quintil y promedia en_riesgo.`

Valor al corte 31/12/2025: 51,8 % (619 de 1.196 clientes de Q5; facturación histórica de esos 619, ARS 113,6 M).

7.5. Cobertura de contacto

Con la lista ordenada por $\hat{F}_i(t)$ descendente entre los clientes en riesgo, la cobertura de contactar a los k primeros es la porción de la exposición que esos k concentran:

$$\text{cobertura}(k,t) = \frac{\sum_{i \in \text{top}_k(t)} \hat{F}_i(t)}{X(t)} \times 100, \qquad \text{azar}(k,t) = \frac{k}{|\{i:\ B_i(t)=1\}|} \times 100 \tag{25}$$

donde $\text{top}_k(t)$ son los k clientes en riesgo de mayor anualizado y $\text{azar}(k,t)$ es lo que cubriría, en esperanza, elegir k al azar. La ventaja del orden es el cociente entre las dos.
Implementación: `pipeline/features.py (top_lista, orden descendente por anualizado) y pipeline/build.py (_anclas_concentracion: anclas concentracion top 500/800 (%), al azar top 500/800 (%), ventaja del orden a 500 (x)). Capacidad declarada [500,800] en el bloque meta (capacidad_contacto). Es la curva de la vista 9 del tablero y el indicador ‘‘Cobertura de contacto’’ de la Parte D, sección 2.1.`
Valor al corte 31/12/2025: con 2.452 en riesgo y $X =$ ARS 94,9 M: contactar 500 cubre 37,0 % de la exposición (al azar 20,4 %; ventaja 1,81×); contactar 800 cubre 52,1 % (ARS 49,5 M; al azar 32,6 %). Lo que queda sin cubrir es la cola de menor anualizado, no un recorte al azar.

7.6. Cobertura ejecutable de la lista

$$\text{ejecutable}(t) = \frac{|\{i \in \text{top}_{800}(t):\ \text{acepta_marketing}_i = 1\}|}{800} \times 100 \tag{26}$$

Implementación: `pipeline/features.py (top_lista, columna mk = acepta_marketing de Clientes.csv sobre los 800); reproducido en entregas/entregable-1/_build/F/recalc_e1.py, líneas C11.`
Valor al corte 31/12/2025: 568 de los 800 de mayor exposición (71,0 %) se pueden contactar; los 232 restantes no dieron consentimiento y no se contactan sin incumplir la Ley 25.326.

7.7. Compra a 7 días sobre contactados

$$\text{compra7d}_g(t) = \frac{1}{|g|} \sum_{j \in g} \text{compra_7dias}_j \tag{27}$$

para un grupo g de envíos de `Campanias_marketing.csv` con `fecha_envio`$\leq t$ (base limpia, sin duplicados de fila completa).
Implementación: `pipeline/series.py:149-158 (tasas). Marca a superar: líneas 171-178, sobre el segmento Inactivos 90d.`
Valor al corte 31/12/2025: global (23.529 envíos limpios al 31/12/2025): abre 35,1 %, clic 8,8 %, compra a 7 días 1,21 %. Marca a superar (segmento `Inactivos 90d`, criterio actual): 1,39 %, 61 compras en 4.399 envíos, intervalo de Wilson al 95 % de 1,08 % a 1,78 %. El desglose por segmento corre sobre el extracto tal cual llega (23.729 envíos, con los 200 `id_envio` repetidos), como lo hace el tablero; sobre la base limpia da 61 en 4.359, 1,40 % (1,09 % a 1,79 %). La diferencia es 0,01 pp y no cambia ninguna conclusión; se declara para que papel y pantalla digan lo mismo.

8. Exposición por ventana de 90 días

El problem statement de la Parte B declara un horizonte de 90 días. $X(t)$ (ecuación (20)) es anual. Para expresar la misma exposición en la ventana que el proyecto dice predecir se prorratea:

$$X_{90}(t) = X(t) \cdot \frac{90}{365} \tag{28}$$

Implementación: `entregas/entregable-1/_build/F/recalc_e1.py, línea C04b (derivada de exposicion anual (M)).`
Valor al corte 31/12/2025: $X_{90} = 94{,}9 \cdot 90/365 =$ ARS 23,4 M por ventana de 90 días.

Supuesto. Es un prorrateo a ritmo constante, no una predicción: reparte la exposición anual de los clientes hoy en riesgo en cuatro ventanas iguales. Sirve para que la magnitud del problema esté en la misma escala que el período declarado (observación B 1.3 de la devolución del 15/09); no dice cuántos de esos pesos se pierden en el próximo trimestre, cosa que sólo un modelo validado podría estimar. Las dos escalas se muestran juntas: ARS 94,9 M/año y ARS 23,4 M por 90 días, ambas al corte 31/12/2025.

9. Poder discriminante de las features

La Parte B (sección 3.1) y la Parte C (sección 1.3) usan el 1,22× de la mejor variable fuera del proxy (la que no entra en la definición de $B_i(t)$). Esta sección define esa cifra y la reproduce.

Población. Los 4.940 clientes elegibles al corte, $E_i(t) = 1$ (ecuación (5)): son los únicos sobre los que $B_i(t)$ puede valer 1, así que medir sobre los 5.978 mezclaría la señal con la composición de elegibilidad (sección 14).

Definición. Para una feature x se parten los elegibles en quintiles por valor de x (Q_1 a Q_5; `pd.qcut(x, 5, duplicates='drop')`: cuando los empates no permiten cinco cortes distintos quedan cuatro, y así ocurre con `n_tiendas_distintas`, `n_categorias_distintas` y `frequency`), se calcula la tasa de riesgo de cada quintil,

$$r_k(x) = \frac{|\{i \in Q_k(x) :\ B_i(t) = 1\}|}{|Q_k(x)|}, \tag{29}$$

y el poder discriminante es el cociente entre la tasa más alta y la más baja:

$$D(x) = \frac{\max_k r_k(x)}{\min_k r_k(x)} \tag{30}$$

Features. `recency_dias` $= \rho_i(t)$; `gap_mediano_compras` $= \gamma_i(t)$; `n_tiendas_distintas` $=$ tiendas físicas distintas donde el cliente compró hasta t (las compras online no cuentan una tienda; sin ninguna compra física vale 0); `n_categorias_distintas` $=$ categorías distintas compradas hasta t; `frequency` $= n_i(t)$, el número de compras; `monetary` $= F_i(t)$, la facturación acumulada.
Implementación: `entregas/entregable-1/_build/F/recalc_e1.py, líneas C21, sobre features.client_facts del corte de referencia.`
Valor al corte 31/12/2025: los seis valores de la tabla 4, reproducidos el 15/09/2026.

Por qué se descartan las dos primeras. $B_i(t)$ se calcula con $\rho_i(t)$ y $\gamma_i(t)$: que "predigan" el riesgo es aritmética, no señal. Entrenar un modelo con ellas como features y $B_i(t)$ como target es el *leakage* que advierte Provost y Fawcett. Descontadas, la mejor señal genuina disponible con los seis datasets del Entregable 1 es `n_tiendas_distintas` con 1,22×. Hasta el Entregable 3, el criterio de éxito 1 de la Parte C pedía un lift de $1{,}30\times$ en el decil superior contra la línea base de recency. La regla del umbral, sin modelo, ya da $2{,}30\times$ (subsección 10.2), y con las señales de reclamos, consultas y devoluciones que llegaron el 08/09 ningún modelo

Feature	$D(x)$	Lectura
`recency_dias`	41,3×	circular: es el término izquierdo de la ecuación (7)
`gap_mediano_compras`	9,9×	circular: define el umbral $\theta_i(t)$ de la ecuación (6)
`n_tiendas_distintas`	1,22×	señal genuina, la mejor
`n_categorias_distintas`	1,21×	señal genuina
`frequency`	1,21×	señal genuina
`monetary`	1,16×	señal moderada

Cuadro 4: Poder discriminante por feature sobre los 4.940 elegibles, corte 31/12/2025.

le gana con un intervalo que excluya el cero. Por eso el criterio se reescribió contra la regla (subsección 10.4). La pasada exploratoria del 05/08 reportó además una feature "tendencia" con 4,5×; su definición no quedó registrada y no se reproduce, así que no se cita.

10. Anticipación: qué confirma la regla y qué promete el modelo

$B_i(t)$ marca al cliente cuando su recencia *ya superó* su umbral propio: $\rho_i(t) > \theta_i(t)$. Es la misma lógica que el segmento "Inactivos 90d" que Casa Óga usa hoy, con el umbral personalizado por el ritmo de cada cliente. Mejora la precisión de a quién se llama "en riesgo"; no anticipa nada. Ninguna vista del tablero del Entregable 1 anticipa: todas describen el corte.

La anticipación la da la lista ordenada por días para cruzar el umbral (subsecciones 10.1 y 10.2); un modelo la reemplaza solo si le gana (subsección 10.8). Lo que se anticipa es este target:

$$Y_i(T) = \mathbb{1}\big[\, E_i(T) = 1 \;\wedge\; B_i(T) = 0 \;\wedge\; \exists\, t \in (T,\, T+90] :\; B_i(t) = 1 \,\big] \tag{31}$$

es decir, entre los clientes elegibles que al corte T todavía no cruzaron su umbral, cuáles lo cruzan dentro de los 90 días siguientes. La condición $E_i(T) = 1$ se agrega en la v2.1 (22/09/2026): un cliente con menos de tres compras no tiene umbral propio y no puede cruzarlo, así que sin esa condición la población del target mezclaría clientes que nunca pueden dar $Y_i(T) = 1$ (sección 14). Un modelo puntúa en T la probabilidad de $Y_i(T) = 1$ con señales que se mueven *antes* del cruce: caída de frecuencia y de ticket respecto del propio historial, y desde el 08/09 reclamos, consultas de soporte y devoluciones. Se valida con holdout temporal (entrenar hasta un corte, evaluar sobre los 90 días siguientes), contra la línea base de ordenar por $\rho_i(T)$ y, desde el Entregable 3, contra la regla del umbral. El dataset de entrenamiento del Entregable 2 materializa esta definición como una fila por cliente elegible y no en riesgo en cada corte mensual T, del 31/01/2023 al 30/09/2025, con las features calculadas solo con datos de fecha $\leq T$ y el target medido en $(T,\, T+90]$; la partición es por corte (entrenamiento hasta 2024, prueba en 2025), nunca aleatoria, y la del Entregable 3 suma un embargo (subsección 10.5). En la versión 0.1 del dataset la existencia se evalúa en tres puntos de la ventana, $t \in \{T+30,\, T+60,\, T+90\}$ días: un cliente que cruza su umbral y vuelve a comprar entre dos evaluaciones queda con $Y_i(T) = 0$. Desde la v0.2 (Entregable 3) el target se evalúa cada día de la ventana, como dice la ecuación (31): suma 885 positivos y ninguno pasa a 0.

Las "dos semanas de anticipación" del alcance (Parte C, sección 1.2) no son un horizonte de predicción: son el tiempo operativo entre el corte mensual en que se calcula la lista y la salida de la campaña, para que Marketing la reciba antes de que arme el envío del mes. El horizonte de predicción es el de la ecuación (31): 90 días.

En el Entregable 3 la anticipación no la da un modelo sino la regla del umbral de la subsección 10.2: ordenar a los clientes por los días que les faltan para cruzar su umbral acierta

81,6 % de la lista mensual en validación y 86,1 % de la lista de contactables en test, y ningún modelo la supera con un intervalo que excluya el cero (subsección 10.8).

10.1. Días para cruzar el umbral y cercanía

Población. Las filas cliente $\times$ corte del dataset `churn_cliente_corte` v0.2: una por cliente elegible y sin riesgo al cierre de cada mes T, 59.585 filas de 4.627 clientes en 33 cortes, del 31/01/2023 al 30/09/2025.

$$h_i(T) = \theta_i(T) - \rho_i(T) \quad \text{(días)}, \qquad \text{cerca}_i(T) = \mathbb{1}\big[h_i(T) < 90\big] \tag{32}$$

Como $B_i(T) = 0$, $h_i(T) \geq 0$. Un cliente con $h_i(T) \geq 90$ no puede cruzar su umbral dentro de $(T,\, T + 90]$: si no compra, su recency llega a lo sumo a $\theta_i(T)$, y si compra vuelve a cero. Su target vale 0.

Implementación: `A-scripts_etapa1.zip: etapa1.py, salida etapa1.json (→ ficha.estructura y tramos_de_cruce).`

Valor (dataset v0.2, 33 cortes): 39.632 filas (66,5 %) a 90 días o más de su umbral, todas con target 0; 19.953 cerca del umbral, con los 16.052 positivos (80,4 % cruza). En validación cruza el 91,7 % de las filas a menos de 30 días, el 76,2 % de 30 a 59 y el 65,5 % de 60 a 89.

10.2. Regla del umbral

Es la línea base 2 de la etapa 1 del modelado (Parte A del Entregable 3) y la regla con la que sale la lista mensual. Usa el umbral θ_i de la ecuación (6), el de la regla de riesgo del tablero. Como clasificador marca como "se va" a todo cliente cerca de su umbral:

$$\hat{y}_i(T) = \text{cerca}_i(T) \tag{33}$$

Como orden, la lista del mes se llena empezando por los clientes con menos días para cruzar, $h_i(T)$ de menor a mayor. Los empates en el último lugar se reparten en proporción, y de ahí los aciertos con decimales. La práctica actual ordena por $\rho_i(T)$ de mayor a menor (más días sin comprar primero). El lift de un orden es la precisión de su decil superior (el 10 % de mayor puntaje de cada corte) dividida por la de la práctica actual.

Implementación: `A-scripts_etapa1.zip: etapa1.py, salida etapa1.json (→ lineas_base_validacion).`

Valor (validación, cortes de julio a septiembre de 2024, 7.173 filas): como clasificador, VP 1.713, FP 540, FN 0 y VN 4.920 (precisión 76,0 %, recall 100 %). En la lista de 500, 81,6 % (1.223,67 aciertos en 1.500) contra 36,2 % de la práctica actual. Decil superior, 90,7 % contra 39,4 %: un lift de 2,30$\times$.

10.3. Precisión de la lista mensual

Es la métrica principal del modelado del Entregable 3. Para un puntaje (el de la regla, el de un modelo o el de la práctica actual), $L(T)$ son las 500 filas de mayor puntaje del corte T; 500 es el piso de lo que Marketing puede contactar por mes (envío 29). Sumando los cortes de validación,

$$P_{500} = \frac{\sum_T \sum_{i \in L(T)} Y_i(T)}{\sum_T |L(T)|}, \qquad R_{500} = \frac{\sum_T \sum_{i \in L(T)} Y_i(T)}{\sum_T \sum_i Y_i(T)} \tag{34}$$

La lista de contactables $L^c(T)$ se arma igual, pero solo con clientes que aceptan marketing y no pidieron la baja con fecha $\leq T$, el filtro L3 de la Parte C del Entregable 3; su recall es sobre los positivos contactables. El ajuste de la etapa 3 busca con una lista proporcional, el 20,9 % de cada corte, la porción que ocupa la lista de 500 en validación (1.500 de 7.173 filas), porque 5 de los 16 cortes de entrenamiento tienen menos de 500 filas.

Implementación: `C-scripts_etapa3.zip: etapa3.py, salida etapa3.json (→ umbral.filas y umbral.filtradas).`
Valor (validación): la regla del umbral acierta 81,6 % de la lista sin filtro y 75,8 % de la de contactables (1.137 aciertos, recall 96,8 %); la regresión logística ajustada, 82,6 % y 73,9 %. Son contactables 5.038 de las 7.173 filas.

10.4. Meta del criterio de éxito 1

La Parte B del Entregable 3 la reescribió contra la regla del umbral, sobre la lista que sale, la de 500 contactables: aciertos por mes de la regla, promedio de los tres cortes de validación.

$$M_1 = \frac{1}{3} \sum_{T} \sum_{i \in L^c(T)} Y_i(T) \tag{35}$$

Se mide sobre el trimestre, no mes a mes. Un modelo reemplaza a la regla solo si suma aciertos por mes con un intervalo del 95 % (bootstrap por cliente, 1.000 réplicas) que excluye el cero, y si esos aciertos pagan lo que agrega al costo (subsecciones 10.7 y 10.8). En una lista de 500, un punto de precisión son 5 aciertos por mes. En producción, la precisión de cada lista se conoce a los 90 días, cuando se sabe quién cruzó; la alerta de la matriz de riesgos de la Parte C del Entregable 3 salta con dos meses seguidos debajo de

$$P_{\text{alerta}} = P^c_{500} - 1{,}96 \sqrt{\frac{P^c_{500}\,(1 - P^c_{500})}{500}} \tag{36}$$

la precisión de validación de la lista de contactables menos el medio intervalo del 95 % de una lista de 500.
Implementación: `entregas/entregable-3/_build/B/contenido_b.py (META_FILT_MES) y _build/C/contenido_c.py (ALERTA_DRIFT), que leen etapa3.json.`
Valor (validación): M_1 = 1.137 / 3 = 379 aciertos por mes (75,8 %). La logística ajustada acierta 29 menos en los tres meses, con un intervalo de $-3{,}25$ a $-1{,}07$ puntos. P_{alerta} = 75,8 % − 3,8 = 72,0 %.

10.5. Partición por corte y embargo

La partición del Entregable 3 es por corte, sin sorteo. Entre conjuntos quedan tres meses para que la ventana del target de uno no llegue al siguiente. Al medir en validación, un corte T entra al entrenamiento solo si su ventana cierra antes del primer corte de validación, T_1^{val} = 31/07/2024:

$$T + 90 \text{ días} < T_1^{\text{val}} \tag{37}$$

Los cortes de mayo y junio de 2024 no lo cumplen. Salen del entrenamiento al medir en validación (embargo) y vuelven para el modelo final. Los de junio a septiembre de 2025 quedan fuera de la evaluación porque su target cae en septiembre a diciembre de 2025, los meses de la caída del extracto (sección 12).

Conjunto	Cortes	Filas	Positivos
Entrenamiento	2023-01 a 2024-04 (16)	14.753	4.636 (31,42 %)
Embargo	2024-05 y 2024-06	4.129	1.062 (25,72 %)
Validación	2024-07 a 2024-09 (3)	7.173	1.713 (23,88 %)
Separación	2024-10 a 2024-12	8.025	2.008 (25,02 %)
Test, reservado hasta la etapa 4	2025-01 a 2025-05 (5)	14.211	3.602 (25,35 %)
Fuera de la evaluación	2025-06 a 2025-09	11.294	3.031 (26,84 %)

Implementación: `A-scripts_etapa1.zip: etapa1.py, salida etapa1.json (→ particion).`

10.6. Evaluación en test

Población. Las filas contactables de los cinco cortes de test, del 31/01 al 31/05/2025, con target medido hasta el 29/08/2025: clientes que aceptan marketing y no pidieron la baja con fecha $\leq T$, el filtro L3 de la Parte C del Entregable 3. Son 9.962 de las 14.211 filas, con 2.521 positivos. $\mathcal{C}$ es el conjunto de cortes evaluados: 5 en test, 3 en validación. El test se abrió una sola vez, el 27/10/2026, con el modelo, la lista y el criterio de la subsección 10.8 fijados antes en `preregistro.json` (v1.1).

La tabla de la evaluación final de la Parte D del Entregable 3 mide la lista de contactables $L^c(T)$ de la subsección 10.3. Predicho positivo es estar en la lista de su corte. Con VP los aciertos, FP los lugares de la lista sin acierto y FN los positivos contactables que quedan fuera, sumados sobre los cortes de $\mathcal{C}$,

$$P^c = \frac{VP}{VP+FP}, \qquad R^c = \frac{VP}{VP+FN}, \qquad \mathrm{F1}^c = \frac{2\,VP}{2\,VP+FP+FN} \tag{38}$$

P^c es la métrica principal: la lista tiene 500 lugares por corte, así que $VP+FP = 500\,|\mathcal{C}|$. R^c es sobre los positivos contactables, no sobre todos. Con empates en el último lugar las cuatro celdas llevan decimales (subsección 10.2).

El AUC-ROC no corta la lista: mide el orden del puntaje $\pi_i(T)$ sobre todas las filas contactables de $\mathcal{C}$, con los cortes juntos. El puntaje es la probabilidad del modelo, $-h_i(T)$ para la regla y $\rho_i(T)$ para la práctica actual. Con n_+ filas positivas y n_- negativas,

$$\mathrm{AUC}^c = \frac{1}{n_+\,n_-} \sum_{i:\,Y_i=1} \sum_{i':\,Y_{i'}=0} \Big(\mathbb{1}\big[\pi_i > \pi_{i'}\big] + \tfrac{1}{2}\,\mathbb{1}\big[\pi_i = \pi_{i'}\big] \Big) \tag{39}$$

la probabilidad de que una fila que cruza su umbral tenga más puntaje que una que no lo cruza. No es el AUC de las Partes B y C del Entregable 3, que se calcula sobre todas las filas, contactables o no.

El valor neto de la lista suma el valor de cada celda (ecuación (46)) y se lleva a un año como si saliera una lista por mes con la composición de los cortes evaluados:

$$V_{\mathcal{C}} = \frac{12}{|\mathcal{C}|}\,\big(VP\,v_{VP} + FP\,v_{FP}\big) \tag{40}$$

Con tres cortes el factor es 4, el de la ecuación (47); con los cinco de test, 2,4. Pasa a dólares con TC.

Implementación: `D-scripts_etapa4.zip: etapa4.py (lista_contactables, medir), salida etapa4.json (→ medicion.principal y tabla_8_1); la columna de validación, en etapa4_validacion.json.`

Valor (test, lista de 500 contactables): la logística ajustada acierta 2.147 de 2.500 lugares: P^c = 85,88 %, R^c = 85,16 % y $\mathrm{F1}^c$ = 85,52 %, con FN = 374 y VN = 7.088. La regla del umbral, 2.153,35: 86,13 %, 85,42 % y 85,77 %. AUC^c = 0,974 para la logística, 0,979 para la regla y 0,660 para la práctica actual. $V_{\mathcal{C}}$ = USD 325,52 por año con la logística y USD 327,06 con la regla. En validación, la logística: 73,9 %, 94,3 %, 82,84 %, 0,966 y USD 252,84.

10.7. Diferencia entre dos listas e intervalo por bootstrap de clientes

Para comparar dos puntajes se resta la precisión de sus listas en los mismos cortes, $D = P^c_{\text{modelo}} - P^c_{\text{regla}}$. Un mismo cliente aparece en varios cortes, así que el intervalo no se arma sorteando filas sino clientes. En cada réplica b, de 1 a 1.000 con semilla 42, se sortean con reposición tantos clientes como tiene el conjunto, se toman todas sus filas, se rehacen las listas de 500 de cada corte con los dos puntajes y se calcula $D^{(b)}$. El intervalo del 95 % va del percentil 2,5 al 97,5 de las réplicas:

$$\mathrm{IC}_{95} = \big[\, q_{0{,}025}\big(D^{(b)}\big),\; q_{0{,}975}\big(D^{(b)}\big) \,\big] \tag{41}$$

La parte de las réplicas con $D^{(b)} > 0$ es la que se cita como réplicas a favor del modelo.
Implementación: `B-scripts_etapa2.zip: etapa2.py (bootstrap_diferencia); D-scripts_etapa4.zip: etapa4.py, salida etapa4.json (→ medicion.principal.diferencia_logistica_menos_regla).`
Valor (test, lista de 500 contactables): $D = -0{,}25$ puntos (6,35 aciertos menos en los cinco cortes), con un intervalo de $-1{,}45$ a $+0{,}79$ y 31,0 % de las réplicas a favor del modelo. En validación, $-1{,}93$ (de $-3{,}25$ a $-1{,}07$). En la lista de 500 sin filtro de test, $+1{,}06$ (de $+0{,}41$ a $+1{,}95$).

10.8. Criterio para reemplazar la regla por un modelo

Es el de la matriz de riesgos de la Parte C del Entregable 3 (fila 13), fijado antes de abrir el test. Un modelo reemplaza a la regla del umbral solo si se cumplen las dos condiciones, medidas en test sobre la lista de 500 contactables:

$$q_{0{,}025}\big(D^{(b)}\big) > 0 \qquad \text{y} \qquad \frac{VP_{\text{modelo}} - VP_{\text{regla}}}{|\mathcal{C}|} \;\geq\; a^{*} = \frac{C_{\text{extra}}\,\mathrm{TC}}{12\,\big(v_{VP} - v_{FP}\big)} \tag{42}$$

La primera pide que la ventaja no sea azar: el intervalo de la ecuación (41) excluye el cero. La segunda pide que los aciertos de más por mes paguen lo que el modelo agrega al costo del año 1, C_{extra} = USD 10.400: dos meses más de data scientist y la nube. Cada acierto de más reemplaza un falso positivo, y por eso vale $v_{VP} - v_{FP}$; a^{*} son los puntos de la subsección 13.4 pasados a aciertos por mes, 5 por punto.
Implementación: `preregistro.json (→ criterio_de_decision.operativo) y etapa4.py (medir, decidir), en D-scripts_etapa4.zip;` a^{*} `en economia.json (→ meta_criterio_1), de B-scripts_etapa2.zip.`
Valor (test): el límite inferior es $-1{,}45$ puntos y la logística acierta 1,27 clientes menos por mes, cuando a^{*} = 8.595. No se cumple ninguna de las dos condiciones: la lista sigue con la regla del umbral.

11. Experimento propuesto y efecto mínimo detectable

El criterio de éxito 5 de la Parte C mide el piloto que propone la Parte B del Entregable 3: tres meses con la lista de 500 por mes, de la que 80 clientes por mes quedan sin contactar como grupo de control. El control se sortea fuera de los clientes de alto valor, el 20 % de mayor facturación acumulada al corte (`monetary`) de cada corte, como pidió Sofía R.: “siempre que ese grupo sea una porción menor y no comprometa a los clientes de mayor valor identificado” (envío 45). Quedan 1.260 tratados y 240 de control. El efecto que mide el piloto vale para el resto de los clientes; para el 20 % de mayor facturación sigue siendo un supuesto.

El control sale de la lista y no del excedente de capacidad: la lista se ordena y se corta, así que el excedente es por construcción el tramo que quedó último, y compararlo contra los contactados mide el ordenamiento, no la campaña.

El efecto mínimo detectable (MDE) entre dos grupos de tamaños N_1 y N_2, para una tasa base p_0, con $\alpha = 0{,}05$ a dos colas y potencia $1 - \beta = 0{,}80$, es el menor δ que cumple

$$\delta \;\geq\; z_{1-\alpha/2}\sqrt{\bar{p}\,(1-\bar{p})\left(\frac{1}{N_1}+\frac{1}{N_2}\right)} \;+\; z_{1-\beta}\sqrt{\frac{p_0(1-p_0)}{N_1}+\frac{p_1(1-p_1)}{N_2}} \tag{43}$$

con $p_1 = p_0 + \delta$ y $\bar{p} = (N_1 p_0 + N_2 p_1)/(N_1 + N_2)$, resuelto por bisección sobre δ. Con $N_1 = N_2$ es la fórmula de dos ramas iguales que usa el tablero.
Implementación: `B-scripts_etapa2.zip: economia.py (mde_desigual), con` p_0 `igual a la compra a 7 días global de la ecuación (27); la misma función reproduce el 2,95 de la vista 13 (entregas/entregable-1/_build/F/recalc_e1.py, líneas C24b), y con ramas iguales da el 1,71 de pipeline/series.py (potencia_experimento).`
Valor (p_0 *= 1,21 %, los 23.529 envíos):* piloto, 1.260 tratados contra 240 de control: MDE $= 2{,}87$ puntos porcentuales. Es lo mínimo que el piloto distingue de cero: prueba que el contacto tiene efecto, no que la

lista se pague (subsección 11.1). La vista 13 del tablero del Entregable 1 muestra el diseño anterior, sobre la lista de 800 ordenada por $\hat{F}_i(t)$: 360 reactivación, 360 cuidado y 80 control por corte, en 3 cortes, asignados por un ciclo fijo de 20 clientes (9, 9 y 2). Ahí el MDE es 1,71 puntos entre las dos ramas de mensaje (1.080 cada una), 2,95 entre una rama y el control (240) y 2,68 entre las dos ramas juntas (2.160) y el control.

11.1. Umbral de producción del piloto

El piloto mide la compra a 7 días de todos los contactados menos la del control. La tasa de éxito s y su equilibrio s^* (subsecciones 13.1 y 13.3) se cuentan sobre los contactados que se iban a ir. Si el contacto cambia solo la compra de esos clientes (los falsos positivos compran igual, como supone la Parte B del Entregable 3), la diferencia que mide el piloto es

$$\Delta = s \cdot P_{500} \tag{44}$$

con P_{500} la precisión de la lista, la parte de los contactados que se iba a ir. Para invertir en producción la diferencia tiene que llegar a $\Delta^* = s^* \cdot P_{500}$.
Implementación: `entregas/entregable-3/_build/C/contenido_c.py (DIF_EQ, S_EQ_FILT), que reproduce` s^* `con la ecuación` (48).
Valor (validación): con la lista de 500 de la regla sin filtro, $s^* = 49{,}56\,\%$ y $P_{500} = 81{,}58\,\%$: $\Delta^* = 40{,}4$ puntos. Con la lista de contactables da lo mismo: $s^* = 53{,}35\,\%$ y $P^c_{500} = 75{,}8\,\%$. Con los factores redondeados a un decimal la cuenta da 40,5, por eso se citan sin redondear. Entre 2,87 y 40,4 puntos el contacto funciona pero no paga la lista, y no se invierte en producción.

12. Limitación: la caída del extracto en 2025

El extracto de transacciones cae en los dos extremos. Sube de 44 ventas en enero de 2022 a 893 en diciembre y baja de 1.390 en enero de 2025 a 255 en diciembre, aunque el ticket medio se mantiene y las altas de clientes no caen. Parece una carga parcial, pero Casa Óga no sabe la causa (consulta 2 del Entregable 2). Como $\rho_i(t)$ se mide contra el corte, si el cierre de 2025 está incompleto la recencia de todos sale inflada, y con ella $B_i(t)$, $X(t)$ y el riesgo por quintil. Las tres cifras (2.452 en riesgo, ARS 94,9 M/año, 51,8 % en Q5) quedan como referencia del tablero y se informan con la sensibilidad de la decisión DC-09 del Entregable 2; la causa de la caída la revisa Casa Óga con Operaciones y el proveedor del POS. Con las decisiones de calidad del Entregable 2, sobre 5.634 clientes con la identidad unida, el riesgo pasa a 50,4 % de los elegibles y la exposición a ARS 96,4 M/año. Con la base corregida del Entregable 2 y el corte al 31/08/2025, 38,5 % y ARS 77,7 M/año. Ninguna de estas cifras se repite sin esta salvedad.

13. Supuesto: la exposición no es recupero

$X(t)$ (ecuación (20)) es la facturación anual proyectada de clientes que hoy están en riesgo, calculada con su propio ritmo histórico de gasto. No mide cuánto recuperaría una campaña de retención: recuperar es una afirmación causal (*si contactamos a estos clientes, vuelven a comprar tanto como antes*) y $X(t)$ no compara contactados contra un grupo de control. Afirmar que Casa Óga “recupera ARS 94,9 M” es una lectura que el dato no sostiene.

Esta distinción ya está declarada en tres lugares del proyecto, y este documento la reafirma como cuarto: en `pipeline/CONTRACT.md` sección 3 (`perdida_esperada` se define como “exposición, no recupero”), en la Parte D sección 2.1 (“Es exposición, no recupero”) y en la misma Parte D, sección 6.1, que deja fuera de alcance de la V1 “la medición de efecto incremental (necesita grupo de control)”. La V2 del proyecto contempla el grupo de control del piloto (Parte

D, sección 6.1, “Plan de evolución”, y sección 11 de este anexo), que es el diseño mínimo para poder hablar de recupero.

Mientras no exista ese grupo de control, cualquier pantalla que muestre $X(t)$ debe rotularlo como *exposición* y no como *ahorro* o *recupero potencial*, y la nota al pie del tablero (Parte D, sección 4.1, `[NOTAS FIJAS AL PIE]`) tiene que sostener esa distinción en cada corte, no solo en el primero.

La Parte B del Entregable 3 cuenta como beneficio el margen que vuelve, con una tasa de éxito, y no la exposición. Las subsecciones que siguen definen esa cuenta. Los montos están en pesos del extracto, sin deflactar, y se pasan a dólares con el tipo de cambio mayorista de referencia del BCRA (Comunicación A 3500) del 30/12/2025, TC = 1.459,42 ARS/USD.

13.1. Tasa de éxito de la acción

Población. Los envíos únicos de `Campanias_marketing.csv` a clientes cerca de su umbral, $\text{cerca}_i(T) = 1$ en el último corte anterior al envío, cruzados por id canónico con el dataset v0.2 en cortes de entrenamiento y de separación (el test no se usa). Con E esos envíos y E^0 los de clientes que no cruzaron ($Y_i(T) = 0$):

$$s = \frac{1}{|E|} \sum_{j \in E} \text{compra_7dias}_j, \qquad r = \frac{1}{|E^0|} \sum_{j \in E^0} \text{compra_7dias}_j \tag{45}$$

s es la tasa de éxito de la acción y r la parte de los falsos positivos que usa el descuento, medida en la misma semana. Sin grupo de control, s mide conversión y no efecto: es un techo. r vale para una oferta de 7 días; si la oferta valiera hasta la próxima compra, la usaría todo el que la abre.

Implementación: `B-scripts_etapa2.zip: economia.py, salida economia.json (→ tasa_exito y tasa_exito_cruzan).`

Valor (envíos cerca del umbral): s = 16 / 1.570 = 1,02 %, con un intervalo de Wilson al 95 % de 0,63 % a 1,65 %: vuelve 1 de cada 98. r = 3 / 408 = 0,74 %, 1 de cada 136. Con una oferta hasta la próxima compra, r sería la apertura de esos 408 envíos, 34,8 %. Sobre los 1.162 envíos a clientes que cruzaron, s = 1,12 %.

13.2. Valor de cada celda de la matriz de confusión

Con m el margen que vuelve con un cliente, d el descuento, $\bar{t}$ el ticket medio y c el costo de la acción, el valor esperado de cada celda frente a no hacer nada es

$$v_{VP} = s\,(m - d\,\bar{t}) - c, \qquad v_{FP} = -c - r\,d\,\bar{t}, \qquad v_{FN} = v_{VN} = 0 \tag{46}$$

Un verdadero positivo vuelve con probabilidad s, compra con el descuento y deja el margen m; la acción se paga siempre. Un falso positivo iba a comprar igual: se paga la acción y, si usa el descuento, se le regala d sobre una compra. El falso negativo va en 0 porque su margen se pierde igual sin proyecto, y cargarlo contaría dos veces el acierto. El margen m es la facturación media de 2024 por registro de cliente activo identificado, multiplicada por el margen bruto de 2024 (`Costo_Margen_Categoria_Mensual.csv`).

Implementación: `B-scripts_etapa2.zip: economia.py (valores), salida economia.json (→ parametros y celda_4_4).`

Valor (2024): m = 40.664 × 37,58 % = ARS 15.282 por año (4.755 registros; por persona unificada, 4.525 y ARS 16.058). d = 15 %, $\bar{t}$ = ARS 20.133 y $d\,\bar{t}$ = ARS 3.020; c = ARS 25, un WhatsApp con oferta personalizada. v_{VP} = ARS 99,96 (USD 0,07) y v_{FP} = ARS $-47{,}21$ (USD $-0{,}03$).

13.3. Valor anual de la lista y tasa de éxito de equilibrio

Las matrices de validación son de tres cortes. Para llevarlas a un año se multiplican por 4, como si saliera una lista de 500 por mes con la composición de validación; con otro número de cortes el factor es 12 sobre esa cantidad (ecuación (40)). Con VP y FP los de la lista en los tres cortes y C_1 el costo del año 1 en dólares,

$$V = 4\left(VP\, v_{VP} + FP\, v_{FP}\right), \qquad \mathrm{ROI} = \frac{V/\mathrm{TC} - C_1}{C_1} \times 100 \tag{47}$$

V está en pesos por año. La tasa de éxito de equilibrio s^* es la que deja el ROI en 0. Despejando s de $V = C_1\,\mathrm{TC}$:

$$s^* = \frac{C_1\,\mathrm{TC}/4 + VP\, c + FP\,(c + r\, d\, \bar{t})}{VP\,(m - d\,\bar{t})} \tag{48}$$

El tipo de cambio de equilibrio, $\mathrm{TC}^* = V/C_1$, es el que deja el ROI en 0 con el beneficio en pesos.

Implementación: `B-scripts_etapa2.zip: economia.py (regla_anual, s_equilibrio_mvp, tc_equilibrio).`

Valor (validación, lista de 500 de la regla sin filtro): con VP 1.223,67 y FP 276,33, V = USD 299,49 por año; con C_1 = USD 20.260, ROI $-98{,}52\,\%$. s^* = 49,6 % con 15 % de descuento, 48,6 veces s, y 39,7 % sin descuento ($d = r = 0$). TC* = 21,57 ARS/USD. Con la lista de 500 contactables (VP 1.137, FP 363), V = USD 264,54 y ROI $-98{,}69\,\%$.

13.4. Valor de un punto de precisión

Con el mismo largo de lista, cada acierto de más es un falso positivo de menos y la acción cuesta lo mismo. En la lista de 500 de los tres cortes de validación, un punto de precisión son 15 aciertos. Por año y en dólares,

$$v_{\text{punto}} = \frac{15 \times 4 \times (v_{VP} - v_{FP})}{\mathrm{TC}} \tag{49}$$

Los puntos que un modelo tiene que sumar sobre la regla para pagar lo que agrega al costo son ese costo dividido por v_{punto}. Un lugar más en la lista suma valor si acierta con una probabilidad mayor que

$$p^* = \frac{-v_{FP}}{v_{VP} - v_{FP}} \tag{50}$$

Implementación: `B-scripts_etapa2.zip: economia.py (valor_punto_usd);` `C-scripts_etapa3.zip: etapa3.py (umbral.precision_de_equilibrio).`

Valor (validación): $v_{VP} - v_{FP}$ = ARS 147,16 y v_{punto} = USD 6,05 por año. El modelo agrega USD 10.400 al costo de la regla: hacen falta 1.719 puntos, y entre la regla (81,6 %) y una lista perfecta hay 18,4. Con s = 100 %, un punto vale USD 505,02 y harían falta 20,6. p^* = 47,21 / 147,16 = 32,1 %.

13.5. Costo por cliente que vuelve

Con la lista de la regla vuelven $4\,VP\,s$ clientes por año. El costo por cliente que vuelve divide el costo anual de las acciones (la acción en cada uno de los $|L|$ contactos de los tres cortes, más el descuento de los VP que vuelven y de los FP que lo usan) por esos clientes:

$$\kappa = \frac{|L|\, c + VP\, s\, d\, \bar{t} + FP\, r\, d\, \bar{t}}{VP\, s} \tag{51}$$

Es un piso, porque s es un techo. Se compara con el costo por alta en el CRM, que no es el de un comprador nuevo: de las 1.477 altas de 2025 con compra, 1.464 ya compraban antes.

Implementación: `B-scripts_etapa2.zip: economia.py, salida economia.json (→ retener_contra_reemplazar)`.
Valor (validación y 2025): con $|L|$ = 1.500, vuelven 49,9 clientes por año; κ = ARS 6.519 con 15 % de descuento y ARS 3.007 sin descuento, contra ARS 11.099 por alta en 2025.

14. Supuesto: el proxy de churn no es churn

$B_i(t)$ (ecuación (7)) es una regla de negocio sobre inactividad relativa al ritmo propio de cada cliente. No es una medición de intención de abandono ni la salida de un modelo predictivo con validación: es un umbral fijo, $\max(90,\ 1{,}5\gamma_i(t))$, elegido por el equipo y sujeto a la misma discusión que cualquier otro parámetro de negocio.

La regla tiene una consecuencia aritmética directa. La ecuación (7) exige $E_i(t) = 1$: un cliente con menos de 3 compras nunca puede estar en riesgo, sin importar cuánto tiempo pasó desde su última compra. Eso significa que la proporción de clientes elegibles no es pareja entre grupos, y donde no es pareja, comparar tasas de riesgo entre esos grupos mezcla dos efectos: cuánto realmente arriesga cada cliente, y qué fracción del grupo llegó siquiera a poder estar en riesgo.

El caso más claro es el quintil de facturación. La tabla 5 muestra los cinco quintiles con su proporción de elegibles y dos versiones de la tasa de riesgo: sobre el total del quintil (como se reporta en el tablero) y sobre los elegibles del quintil (la que aísla el comportamiento real).

Quintil	Clientes	Elegibles	% elegibles	% riesgo / total	% riesgo / elegibles
Q1	1.196	389	32,5 %	13,3 %	40,9 %
Q2	1.195	1.067	89,3 %	42,5 %	47,6 %
Q3	1.196	1.123	93,9 %	47,8 %	50,9 %
Q4	1.195	1.173	98,2 %	49,7 %	50,6 %
Q5	1.196	1.188	99,3 %	51,8 %	52,1 %

Cuadro 5: Composición de elegibilidad y tasa de riesgo por quintil, corte 31/12/2025. Fuente: `pipeline/features.py:81-84,89`, agrupado por `quintil`.

$$\text{gradiente}_{\text{total}} = \frac{\%\text{riesgo}_{Q5}/\text{total}}{\%\text{riesgo}_{Q1}/\text{total}} = \frac{51,8}{13,3} = 3{,}89 \tag{52}$$

$$\text{gradiente}_{\text{elegibles}} = \frac{\%\text{riesgo}_{Q5}/\text{elegibles}}{\%\text{riesgo}_{Q1}/\text{elegibles}} = \frac{52,1}{40,9} = 1{,}27 \tag{53}$$

Implementación: `cálculo propio sobre pipeline/features.py:81-84,89. Verificación independiente de las anclas publicadas: pipeline/build.py:210-211 solo chequea 51,8% y 13,3% sobre el total, no el gradiente.`
Valor al corte 31/12/2025: $3{,}89\times$ midiendo sobre toda la base, $1{,}27\times$ midiendo solo entre elegibles.

El gradiente que se muestra en el tablero (Q5 casi cuadruplica a Q1) es en su mayor parte composición: en Q1 solo 1 de cada 3 clientes llegó a las 3 compras que exige la elegibilidad, así que 2 de cada 3 no podían estar en riesgo pase lo que pase; en Q5 esa restricción casi no filtra a nadie (99,3 % elegibles). Entre los clientes que sí pudieron estar en riesgo en ambos quintiles, la diferencia de comportamiento es bastante más chica: $1{,}27\times$, no $3{,}89\times$. Cualquier lectura del tipo “los clientes de más valor abandonan cuatro veces más” sobreestima el efecto real en un factor de aproximadamente 3; la lectura defendible es que abandonan proporcionalmente más, una vez que se descuenta que en Q1 la mayoría ni siquiera acumuló historia suficiente para entrar en la medición.