

Casa Óga — Formulación del tablero de riesgo de clientes

Materia 82.21 — Factibilidad de Proyectos Data Driven
Entregables 1 y 2 — Grupo 2 — Anexo de fórmulas, v2.1

Sebastián Caules	64331
Tomás Ferreccio	64934
Matías Sola	64322
Francisco Cattaneo	64900
Juan Manuel Rilo	64037

15/09/2026 (v1.0: 01/09/2026)

Este documento fija la notación y la trazabilidad de las fórmulas del tablero de riesgo de clientes de Casa Óga. Cada fórmula indica la línea de código que la implementa y el valor que produce sobre el corte de referencia, 31/12/2025. La decisión D4 del proyecto vuelve móvil el mes de corte: por eso cada fórmula lleva el parámetro t explícito en la notación, nunca implícito. El pipeline recalcula todo desde cero en cada corte, usando solo transacciones con fecha $\leq t$ (pipeline/features.py:69). Los valores citados corresponden a la corrida de pipeline/build.py, que verificó 134 anclas del contrato de datos (pipeline/CONTRACT.md sección 5) antes de escribir el payload.

Índice

1. Tabla de símbolos	2
2. Limpieza de transacciones	2
3. Métricas por cliente	3
3.1. Facturación acumulada	3
3.2. Recency	3
3.3. Gap mediano propio	4
3.4. Elegibilidad	4
3.5. Riesgo	4
3.6. Anualización del gasto	4
3.7. Quintil de facturación	5
3.8. Región dominante	5
3.9. Categoría dominante	5
4. Segmentación RFM	6
4.1. Scores R, F, M	6
4.2. Reglas de segmento	6
5. Tabla de contingencia	7
5.1. Clave empaquetada k	7
5.2. Celdas agregadas	7
6. Exposición agregada	7
6.1. Descomposición por dimensión	8

7. Indicadores de la Parte D, sección 2.1	8
7.1. Tasa de recompra a 90 días	8
7.2. Ingreso anual en riesgo (exposición)	9
7.3. Clientes en riesgo	9
7.4. Riesgo en el quintil de mayor valor (Q5)	9
7.5. Cobertura de contacto	9
7.6. Cobertura ejecutable de la lista	9
7.7. Compra a 7 días sobre contactados	10
8. Exposición por ventana de 90 días	10
9. Poder discriminante de las features	10
10. Anticipación: qué confirma la regla y qué promete el modelo	11
11. Experimento propuesto y efecto mínimo detectable	12
12. Limitación: la carga parcial del extracto en 2025	12
13. Supuesto: la exposición no es recupero	12
14. Supuesto: el proxy de churn no es churn	13

1. Tabla de símbolos

Un símbolo tiene un único significado en todo el documento. La tabla cubre las 25 fechas de corte, los campos por cliente y los agregados de la tabla de contingencia.

Símbolo	Significado
t	Corte: fin de mes usado como parámetro móvil. 25 valores, 2023-12-31 a 2025-12-31 (pipeline/loader.py:20-22). Corte de referencia de este documento: 2025-12-31.
i	Índice de un cliente individual (id_cliente).
$F_i(t)$	Facturación acumulada del cliente i con fecha $\leq t$: suma de monto_netto.
$n_i(t)$	Cantidad de compras del cliente i hasta t .
$p_i(t)$	Fecha de la primera compra de i hasta t .
$u_i(t)$	Fecha de la última compra de i hasta t .
$\rho_i(t)$	Recency: días entre $u_i(t)$ y t .
$\gamma_i(t)$	Gap mediano propio: mediana de los días entre compras consecutivas de i hasta t .
$E_i(t)$	Indicador de elegibilidad, 1 si $n_i(t) \geq 3$, si no 0.
$\theta_i(t)$	Umbral de riesgo del cliente i , en días: $\max(90, 1,5 \gamma_i(t))$.
$B_i(t)$	Indicador de riesgo (proxy operativo de <i>churn</i>), 1 si i está en riesgo, si no 0.
$A_i(t)$	Años de historia del cliente i : $(t - p_i(t))/365,25$.
$\hat{F}_i(t)$	Facturación anualizada del cliente i .
$Q_i(t)$	Quintil de facturación de i , 1 a 5.
$\text{reg}_i(t)$	Región donde i concentra su gasto en tienda física, o Solo online.
$\text{cat}_i(t)$	Categoría donde i concentra su gasto.
$\mathcal{R}_i(t), \mathcal{F}_i(t), \mathcal{M}_i(t)$	Scores RFM de i : cuantiles (1 a 5) de recency, frecuencia (cantidad de compras) y monto (facturación).
$S_i(t)$	Segmento RFM asignado a i : una de siete etiquetas excluyentes.
r, c, s	Índices 0-based de región (0 a 5), categoría (0 a 6) y segmento RFM (0 a 6) de un cliente, usados para construir k .
q	Quintil de facturación, 1 a 5, usado (como $q - 1$) para construir k .
k	Clave empaquetada de una celda de la tabla de contingencia región×categoría×RFM×quintil.
$n_k(t)$	Cientes de la celda k en el corte t .
$nr_k(t)$	Cientes en riesgo de la celda k .
$ne_k(t)$	Cientes elegibles de la celda k .
$f_k(t)$	Facturación histórica total de la celda k .
$fr_k(t)$	Facturación histórica de los clientes en riesgo de la celda k .
$a_k(t)$	Facturación anualizada total de la celda k .
$ar_k(t)$	Facturación anualizada de los clientes en riesgo de la celda k (exposición de la celda).
$X(t)$	Exposición agregada: suma de $\hat{F}_i(t)$ sobre los clientes en riesgo.

2. Limpieza de transacciones

La limpieza se aplica en orden fijo sobre Transacciones_clientes.csv y cada etapa reporta su propio conteo: los cuatro números viajan en el payload bajo stage_counts, no son un registro

de depuración.

$$tx_{\text{crudo}} \xrightarrow{\text{drop_duplicates}()} tx_{\text{dedupe}} \xrightarrow{\text{id_cliente no nulo}} tx_{\text{identificado}} \xrightarrow{\text{monto_neto} > 0} tx_{\text{limpio}} \quad (1)$$

Etapas	Regla	Conteo
crudo	lectura tal cual	50.250
dedupe	drop_duplicates() de fila completa	50.000
identificado	id_cliente no nulo	27.606
monto > 0	monto_neto > 0	27.276

Implementación: pipeline/loader.py:35 (dedupe), :36 (identificado), :37 (monto_neto > 0); los mismos filtros se repiten en stage_counts, pipeline/loader.py:54-56.
Valor al corte 31/12/2025: 50.250 → 50.000 → 27.606 → 27.276, los cuatro chequeados como anclas en pipeline/build.py:213-219.

Dos notas de calidad que el pipeline declara en vez de corregir en silencio: las 250 filas que saca el dedupe son exactamente las de id_transaccion duplicado (dup_ids_crudo = 250, dup_ids_post = 0); y los montos ≤ 0 son 613 en crudo y 608 tras el dedupe, todos estrictamente negativos, ninguno en cero. El canal se normaliza de 4 etiquetas a 2 (Tienda/tienda → fisico, Online/E-commerce → online), pipeline/loader.py:12-17,40. No se deflacta por IPC. Casa Óga declaró que monto_neto está en pesos corrientes del día de la venta (relevamiento, envío 54), pero el extracto no tiene deriva de precios (precio unitario implícito -7,6 % de 2022 a 2025, plano en las siete categorías; medición del 27/08/2026): no hay inflación en el dato que corregir. Todo importe de este documento es en pesos del extracto tal como llegan, y la pregunta de si el extracto se normalizó al exportarlo vuelve al negocio en el Entregable 2.

3. Métricas por cliente

3.1. Facturación acumulada

$$F_i(t) = \sum_{\substack{j: \text{cliente}(j)=i \\ \text{fecha}_j \leq t}} \text{monto_neto}_j \quad (2)$$

Implementación: pipeline/features.py:71-72 (agg.facturacion, groupby("id_cliente").sum()).

Valor al corte 31/12/2025: facturación de toda la base = ARS 550,2 M; facturación de los clientes en riesgo = ARS 262,8 M.

3.2. Recency

$$\rho_i(t) = t - u_i(t) \quad (\text{días}) \quad (3)$$

Implementación: pipeline/features.py:78.

Valor al corte 31/12/2025: mediana 277 días sobre los 5.978 clientes con compra válida (rango 2 a 1.438 días). Ejemplo CLI00002: $\rho = 73$ días.

3.3. Gap mediano propio

$$\gamma_i(t) = \text{mediana}(\{u_{i,m+1} - u_{i,m}\}_{m=1}^{n_i(t)-1}) \quad (\text{días entre compras consecutivas}) \quad (4)$$

Implementación: pipeline/features.py:18-23 (_gap_mediano_por_cliente), :79 (asignación).
Valor al corte 31/12/2025: mediana de la base 163 días, sobre los 5.663 clientes con dos compras o más.
 Ejemplo CLI00002: $\gamma = 57$ días; CLI00004: $\gamma = 120,5$ días.

Los 315 clientes con una sola compra no tienen $\gamma_i(t)$ definido (diferencia sobre una serie de un solo punto). Verificado: esos 315 coinciden exactamente con los clientes de $n_i(t) = 1$, y ninguno es elegible, así que el valor indefinido nunca llega a la regla de riesgo (sección 3.5).

3.4. Elegibilidad

$$E_i(t) = \mathbf{1}[n_i(t) \geq 3] \quad (5)$$

Implementación: pipeline/features.py:81.
Valor al corte 31/12/2025: 4.940 elegibles de 5.978 clientes (82,6 %).

3.5. Riesgo

$$\theta_i(t) = \max(90, 1,5 \gamma_i(t)) \quad (\text{días}) \quad (6)$$

$$B_i(t) = E_i(t) \wedge [\rho_i(t) > \theta_i(t)] \quad (7)$$

Implementación: pipeline/features.py:82-84.
Valor al corte 31/12/2025: 2.452 clientes en riesgo de 5.978 (41,0 %).

Un cliente no elegible nunca puede estar en riesgo, aunque lleve años sin comprar: la ecuación (7) exige $E_i(t) = 1$ antes de evaluar el umbral. La sección 14 desarrolla la consecuencia aritmética de esta exigencia.

Dos ejemplos concretos del umbral $\theta_i(t)$, verificados sobre el corte de referencia: CLI00002 tiene 8 compras y $\gamma = 57$, así que $\theta = \max(90, 85,5) = 90$ (domina el piso) y con $\rho = 73 < 90$ no está en riesgo. CLI00004 tiene 5 compras y $\gamma = 120,5$, así que $\theta = \max(90, 180,75) = 180,75$ (domina $1,5\gamma$) y con $\rho = 287 > 180,75$ sí está en riesgo. Entre los 4.940 elegibles, el piso de 90 días domina en 351 casos y $1,5\gamma$ domina en los 4.589 restantes.

3.6. Anualización del gasto

$$A_i(t) = \frac{t - p_i(t)}{365,25} \quad (\text{años}) \quad (8)$$

$$\hat{F}_i(t) = \begin{cases} F_i(t) & \text{si } A_i(t) = 0 \\ F_i(t) / A_i(t) & \text{si } A_i(t) > 0 \end{cases} \quad (9)$$

Implementación: pipeline/features.py:86-87.
Valor al corte 31/12/2025: base anualizada total = ARS 204,6 M; exposición (anualizado de los en riesgo) = ARS 94,9 M.

Supuesto. $A_i(t)$ se mide desde la *primera* compra hasta el corte, no hasta la última. Es el punto no obvio del caso: la alternativa intuitiva sería medir la ventana de compras observada, de $p_i(t)$ a $u_i(t)$. Esa alternativa castiga exactamente a los clientes que interesa medir bien: un cliente que compró seguido durante seis meses y después dejó de comprar tendría una ventana

corta (0,5 años) sobre una facturación ya alta, y su gasto anualizado se dispararía por el solo hecho de estar inactivo. Usar t (el corte, no $u_i(t)$) como fin de la ventana evita ese sesgo: el denominador sigue creciendo mes a mes aunque el cliente no vuelva a comprar, así que la inactividad no infla la proyección anual. La contrapartida es la opuesta: un cliente nuevo con muy poca historia (denominador chico) puede anualizar de más. Se mide en vez de corregir en silencio: 111 clientes (1,9 % de la base) tienen menos de un año de historia al corte de referencia, contra 2.661 (52,0 %) en el primer corte de la serie (2023-12-31), cuando casi toda la base era reciente. Ninguno de los 111 con historia corta del corte de referencia está en riesgo antes de los 0,605 años de antigüedad (el mínimo de $A_i(t)$ entre los $B_i(t) = 1$), así que el sesgo de historia corta no contamina la exposición $X(t)$ de la sección 6, sólo infla algunos términos de la base anualizada total que no están en riesgo.

El comentario original en `pipeline/build.py:74-75` declara para este mismo corte “31 clientes y 2,8 % de la base”: ese número no reprodujo al correr el código (`pipeline/build.py:76-77`, `corta = anios < 1.0`, sobre facts del corte 2025-12-31 da 111 clientes). El valor que viaja en el payload bajo `exposicion_por_corte[-1].clientes_historia_corta` es 111, y es el que se reporta acá; el comentario del código quedó desactualizado y no se fuerza para que coincida.

3.7. Quintil de facturación

$$Q_i(t) = \text{qcut}_5(F_i(t)) \in \{1, \dots, 5\} \quad (10)$$

Implementación: `pipeline/features.py:89` (`pd.qcut(facturacion, 5, ...)`).

Valor al corte 31/12/2025: ver tabla 5 (sección 14). Rangos de facturación: Q1 de ARS 500 a 42.953; Q5 de ARS 135.867 a 415.135.

3.8. Región dominante

$$\text{reg}_i(t) = \begin{cases} \arg \max_r \sum_{\substack{j: \text{región}(j)=r \\ \text{canal}(j)=\text{fisico}, \text{fecha}_j \leq t}} \text{monto_neto}_j & \text{si } i \text{ tiene compra en tienda física} \\ \text{Solo online} & \text{si no} \end{cases} \quad (11)$$

Implementación: `pipeline/features.py:26-32` (`_region_dominante`); asignación en la línea 91.

Valor al corte 31/12/2025: 317 clientes Solo online al 31/12/2025 (5,3 % de la base). Ejemplo CLI00002: Centro.

3.9. Categoría dominante

$$\text{cat}_i(t) = \arg \max_c \sum_{\substack{j: \text{categoría}(j)=c \\ \text{fecha}_j \leq t}} \text{monto_neto}_j \quad (12)$$

Implementación: `pipeline/features.py:35-38` (`_categoria_dominante`), :92 (asignación).

Valor al corte 31/12/2025: Muebles concentra la mayor cantidad de clientes (1.897, 44,4 % en riesgo); Baño la menor (166, 28,9 % en riesgo). Ejemplo CLI00002: Muebles.

4. Segmentación RFM

4.1. Scores R, F, M

$$\mathcal{R}_i(t) = \text{qcut}_5\left(\text{rank}_{\text{first}}^{\downarrow}(\rho_i(t))\right) \quad (13)$$

$$\mathcal{F}_i(t) = \text{qcut}_5\left(\text{rank}_{\text{first}}^{\uparrow}(n_i(t))\right) \quad (14)$$

$$\mathcal{M}_i(t) = \text{qcut}_5\left(\text{rank}_{\text{first}}^{\uparrow}(E_i(t))\right) \quad (15)$$

donde $\text{rank}_{\text{first}}^{\uparrow}$ ordena de menor a mayor y $\text{rank}_{\text{first}}^{\downarrow}$ de mayor a menor, empates resueltos por orden de aparición (`method="first"`), y qcut_5 reparte esos rangos en 5 bloques del mismo tamaño, etiquetados 1 a 5 en el orden del ranking. El score $\mathcal{R}_i(t)$ queda invertido respecto de $\rho_i(t)$: recency baja (compró hace poco) da score alto, como pide el contrato.

Implementación: `pipeline/features.py:41-45` (`_qcut_rank_5`), `:94-96` (asignación de R, F, M).

Valor al corte 31/12/2025: sin valor único por ser cálculo por cliente. Cada score reparte 1.195 o 1.196 clientes por quintil, por construcción de `qcut`.

4.2. Reglas de segmento

Siete reglas excluyentes, evaluadas en este orden; la primera que aplica gana y saca al cliente de la evaluación de las siguientes (`pipeline/features.py:48-65`, variable `aun_sin_asignar`):

1. Campeones: $\mathcal{R}_i(t) \geq 4 \wedge \mathcal{F}_i(t) \geq 4 \wedge \mathcal{M}_i(t) \geq 4$
2. En riesgo: $\mathcal{R}_i(t) \leq 2 \wedge \mathcal{F}_i(t) \geq 3$
3. Leales: $\mathcal{R}_i(t) \geq 3 \wedge \mathcal{F}_i(t) \geq 4$
4. Hibernando: $\mathcal{R}_i(t) \leq 2 \wedge \mathcal{F}_i(t) \leq 2$
5. Nuevos: $\mathcal{R}_i(t) \geq 4 \wedge n_i(t) = 1$ (conteo literal de compras, no el score $\mathcal{F}$)
6. Potenciales: $\mathcal{R}_i(t) \geq 4 \wedge \mathcal{F}_i(t) \leq 2$
7. Perdidos: el resto

Implementación: `pipeline/features.py:48-65` (`_segmento_rfm`), `:98` (asignación de $S_i(t)$).

Valor al corte 31/12/2025: ver tabla 2.

Segmento $S_i(t)$	Clientes
Campeones	1.014
En riesgo	1.018
Leales	820
Hibernando	1.373
Nuevos	34
Potenciales	591
Perdidos	1.128
Total	5.978

Cuadro 2: Segmentos RFM al corte de referencia. Coincide exacto con la nota de `pipeline/CONTRACT.md` sección 3 (verificado por corrida propia).

Por construcción, la regla Nuevos exige $n_i(t) = 1$, que nunca cumple $E_i(t) = 1$ (la elegibilidad pide $n_i(t) \geq 3$): los 34 clientes Nuevos tienen 0 elegibles y 0 en riesgo, verificado sobre el corte de referencia.

5. Tabla de contingencia

5.1. Clave empaquetada k

Con $|C| = 7$ categorías, $|S| = 7$ segmentos RFM y $|Q| = 5$ quintiles, la celda de un cliente se codifica en base mixta:

$$k(i, t) = ((r_i(t) \cdot 7 + c_i(t)) \cdot 7 + s_i(t)) \cdot 5 + (q_i(t) - 1) \quad (16)$$

donde $r_i(t)$, $c_i(t)$, $s_i(t)$ son los índices 0-based de $\text{reg}_i(t)$, $\text{cat}_i(t)$ y $S_i(t)$ en las listas fijas del contrato, y $q_i(t) = Q_i(t)$. Es una codificación posicional de base mixta (como convertir un número de varios dígitos, cada uno con su propia base): región no lleva módulo por ser el dígito más significativo, categoría y segmento usan base 7, quintil usa base 5. El espacio total es $6 \times 7 \times 7 \times 5 = 1.470$ combinaciones posibles, k entre 0 y 1.469.

Implementación: pipeline/features.py:104-109 (contingency, línea 109 la fórmula de k).

Valor al corte 31/12/2025: ejemplo a mano, cliente CLI00002: región Centro ($r = 1$), categoría Muebles ($c = 4$), segmento Campeones ($s = 0$), quintil 5 ($q = 5$). $k = ((1 \cdot 7 + 4) \cdot 7 + 0) \cdot 5 + (5 - 1) = 389$, verificado contra la salida real de `contingency()`. La primera celda ocupada de la tabla ordenada por k es $k = 3$ (región AMBA, categoría Baño, segmento Campeones, quintil 4), con 2 clientes.

5.2. Celdas agregadas

Por cada celda k ocupada en el corte t , seis enteros:

$$n_k(t) = \sum_{i: k(i,t)=k} 1, \quad nr_k(t) = \sum_{i: k(i,t)=k} B_i(t), \quad ne_k(t) = \sum_{i: k(i,t)=k} E_i(t) \quad (17)$$

$$f_k(t) = \sum_{i: k(i,t)=k} F_i(t), \quad fr_k(t) = \sum_{i: k(i,t)=k} B_i(t) \cdot F_i(t) \quad (18)$$

$$a_k(t) = \sum_{i: k(i,t)=k} \hat{F}_i(t), \quad ar_k(t) = \sum_{i: k(i,t)=k} B_i(t) \cdot \hat{F}_i(t) \quad (19)$$

Implementación: pipeline/features.py:111-125 (construcción de la tabla y `groupby("k").sum()`).

Valor al corte 31/12/2025: 664 celdas ocupadas de 1.470 posibles (45,2%) al corte de referencia.

Reconciliación exacta: $\sum_k n_k(t) = 5.978$, $\sum_k nr_k(t) = 2.452$, $\sum_k ar_k(t) = 94.925.989$ (ARS 94,9 M), igual a $X(t)$ de la sección 6. Toda combinación de filtros del tablero es una suma de estas celdas: el navegador no recalcula riesgo, recency, quintiles ni RFM.

6. Exposición agregada

$$X(t) = \sum_{i: B_i(t)=1} \hat{F}_i(t) = \sum_k ar_k(t) \quad (20)$$

Implementación: pipeline/build.py:185. La igualdad con $\sum_k ar_k(t)$ es la que usa pipeline/pack.py:13-16 para derivar la serie `exposicion_por_corte`: suma ar de cada contingencia y no vuelve a tocar facts.

Valor al corte 31/12/2025: $X(31/12/2025) = \text{ARS } 94.925.989$ ($\approx \text{ARS } 94,9 \text{ M}$).

6.1. Descomposición por dimensión

$$X(t) = \sum_r X_r(t) = \sum_c X_c(t) = \sum_s X_s(t) = \sum_q X_q(t) \quad (21)$$

$$X_d(t) = \sum_{i: B_i(t)=1, d_i(t)=d} \hat{F}_i(t) \quad (22)$$

Implementación: misma agregación de la ecuación (20), agrupada por dimensión en vez de sumada entera. No hay función separada en el pipeline: es un groupby sobre los clientes en riesgo de facts.

Valor al corte 31/12/2025: ver tabla 3. Las cuatro descomposiciones cierran contra ARS 94,9 M dentro del redondeo de un decimal.

Región	ARS M	Categoría	ARS M	Quintil	ARS M
AMBA	40,5	Muebles	45,4	Q1	2,2
Centro	19,7	Decoración	18,9	Q2	11,4
NOA	16,1	Iluminación	13,0	Q3	17,8
Cuyo	15,0	Textil hogar	10,3	Q4	24,8
Patagonia	2,5	Cocina y mesa	5,0	Q5	38,7
Solo online	1,2	Organización	1,3		
		Baño	1,1		

Cuadro 3: Exposición $X(t)$ descompuesta por región, categoría y quintil (RFM en el texto: En riesgo 36,0 M, Leales 21,3 M, Campeones 15,5 M, Hibernando 12,3 M, Perdidos 8,7 M, Potenciales 1,1 M, Nuevos 0). El quintil 5 solo concentra el 40,8 % de la exposición total pese a no ser mayoría de clientes en riesgo: es el que más factura, no el que más gente en riesgo tiene.

7. Indicadores de la Parte D, sección 2.1

Los siete indicadores de la Parte D sección 2.1 se trazan acá contra su implementación, uno por subsección: recompra, exposición, clientes en riesgo, riesgo en Q5, cobertura de contacto, cobertura ejecutable y compra a 7 días.

7.1. Tasa de recompra a 90 días

$$\tau_q(t) = \frac{|\{i \in \text{clientes con última compra en el trimestre } q : \exists \text{ compra en } (u_{i,q}, u_{i,q} + 90]\}|}{|\{i : \text{última compra de } i \text{ en el trimestre } q\}|} \quad (23)$$

Un trimestre solo entra en el cálculo si su cierre más 90 días cae dentro del horizonte de datos disponible; si no, τ_q queda indefinido en vez de calcularse sobre una muestra sesgada de clientes con última compra temprana en el trimestre.

Implementación: pipeline/series.py:12-90 (recompra_trimestral). Gate de observabilidad: líneas 44-59. Conteo de retorno: líneas 61-71.

Valor al corte 31/12/2025: 2025Q3 (último trimestre observable con horizonte al 31/12/2025): $\tau = 8,5\%$ ($n = 1.330$ clientes calculables), contra la meta de 10-11 % y la referencia de 8-9 % que estimó el negocio en el relevamiento (envío 3 / planilla 3, “un nivel base cercano al 8-9 %”; no es una línea base medida: la serie estuvo entre 16 % y 19 % de 2023Q1 a 2025Q1) (pipeline/build.py meta, meta_recompra/base_recompra). Pico de la serie: 2024Q2 con 19,0 %.

7.2. Ingreso anual en riesgo (exposición)

Ya definido en la ecuación (20).

Implementación: pipeline/build.py:185.

Valor al corte 31/12/2025: ARS 94,9 M.

7.3. Clientes en riesgo

Ya definido en la ecuación (7).

Implementación: pipeline/features.py:82-84.

Valor al corte 31/12/2025: 2.452 de 5.978 (41,0 %).

7.4. Riesgo en el quintil de mayor valor (Q5)

$$\%riesgo_{Q5}(t) = \frac{|\{i : Q_i(t) = 5, B_i(t) = 1\}|}{|\{i : Q_i(t) = 5\}|} \times 100 \quad (24)$$

Implementación: pipeline/build.py:187,210. Agrupa facts por quintil y promedia en_riesgo.

Valor al corte 31/12/2025: 51,8 % (619 de 1.196 clientes de Q5; facturación histórica de esos 619, ARS 113,6 M).

7.5. Cobertura de contacto

Con la lista ordenada por $\hat{F}_i(t)$ descendente entre los clientes en riesgo, la cobertura de contactar a los k primeros es la porción de la exposición que esos k concentran:

$$\text{cobertura}(k, t) = \frac{\sum_{i \in \text{top}_k(t)} \hat{F}_i(t)}{X(t)} \times 100, \quad \text{azar}(k, t) = \frac{k}{|\{i : B_i(t) = 1\}|} \times 100 \quad (25)$$

donde $\text{top}_k(t)$ son los k clientes en riesgo de mayor anualizado y $\text{azar}(k, t)$ es lo que cubriría, en esperanza, elegir k al azar. La ventaja del orden es el cociente entre las dos.

Implementación: pipeline/features.py (top_lista, orden descendente por anualizado) y pipeline/build.py (_anclas_concentracion: anclas concentracion top 500/800 (%), al azar top 500/800 (%), ventaja del orden a 500 (x)). Capacidad declarada [500,800] en el bloque meta (capacidad_contacto). Es la curva de la vista 9 del tablero y el indicador “Cobertura de contacto” de la Parte D, sección 2.1.

Valor al corte 31/12/2025: con 2.452 en riesgo y $X = \text{ARS } 94,9 \text{ M}$: contactar 500 cubre 37,0 % de la exposición (al azar 20,4 %; ventaja 1,81×); contactar 800 cubre 52,1 % (ARS 49,5 M; al azar 32,6 %). Lo que queda sin cubrir es la cola de menor anualizado, no un recorte al azar.

7.6. Cobertura ejecutable de la lista

$$\text{ejecutable}(t) = \frac{|\{i \in \text{top}_{800}(t) : \text{acepta_marketing}_i = 1\}|}{800} \times 100 \quad (26)$$

Implementación: pipeline/features.py (top_lista, columna mk = acepta_marketing de Clientes.csv sobre los 800); reproducido en entregas/entregable-1/_build/F/recalc_e1.py, líneas C11.

Valor al corte 31/12/2025: 568 de los 800 de mayor exposición (71,0 %) se pueden contactar; los 232 restantes no dieron consentimiento y no se contactan sin incumplir la Ley 25.326.

7.7. Compra a 7 días sobre contactados

$$\text{compra7d}_g(t) = \frac{1}{|g|} \sum_{j \in g} \text{compra_7dias}_j \quad (27)$$

para un grupo g de envíos de `Campanias_marketing.csv` con `fecha_envio` $\leq t$ (base limpia, sin duplicados de fila completa).

Implementación: `pipeline/series.py:149-158` (tasas). Marca a superar: líneas 171-178, sobre el segmento Inactivos 90d.

Valor al corte 31/12/2025: global (23.529 envíos limpios al 31/12/2025): abre 35,1 %, clic 8,8 %, compra a 7 días 1,2 %. Marca a superar (segmento Inactivos 90d, criterio actual): 1,39 %, 61 compras en 4.399 envíos, intervalo de Wilson al 95 % de 1,08 % a 1,78 %. El desglose por segmento corre sobre el extracto tal cual llega (23.729 envíos, con los 200 `id_envio` repetidos), como lo hace el tablero; sobre la base limpia da 61 en 4.359, 1,40 % (1,09 % a 1,79 %). La diferencia es 0,01 pp y no cambia ninguna conclusión; se declara para que papel y pantalla digan lo mismo.

8. Exposición por ventana de 90 días

El problem statement de la Parte B declara un horizonte de 90 días. $X(t)$ (ecuación (20)) es anual. Para expresar la misma exposición en la ventana que el proyecto dice predecir se prorratea:

$$X_{90}(t) = X(t) \cdot \frac{90}{365} \quad (28)$$

Implementación: `entregas/entregable-1/_build/F/recalc_e1.py`, línea C04b (derivada de `exposicion anual (M)`).

Valor al corte 31/12/2025: $X_{90} = 94,9 \cdot 90/365 = \text{ARS } 23,4 \text{ M}$ por ventana de 90 días.

Supuesto. Es un prorrateo a ritmo constante, no una predicción: reparte la exposición anual de los clientes hoy en riesgo en cuatro ventanas iguales. Sirve para que la magnitud del problema esté en la misma escala que el período declarado (observación B 1.3 de la devolución del 15/09); no dice cuántos de esos pesos se pierden en el próximo trimestre, cosa que sólo un modelo validado podría estimar. Las dos escalas se muestran juntas: ARS 94,9 M/año y ARS 23,4 M por 90 días, ambas al corte 31/12/2025.

9. Poder discriminante de las features

La Parte B (sección 3.1) y la Parte C (sección 1.3) usan el $1,22\times$ de la mejor variable fuera del proxy (la que no entra en la definición de $B_i(t)$). Esta sección define esa cifra y la reproduce.

Población. Los 4.940 clientes elegibles al corte, $E_i(t) = 1$ (ecuación (5)): son los únicos sobre los que $B_i(t)$ puede valer 1, así que medir sobre los 5.978 mezclaría la señal con la composición de elegibilidad (sección 14).

Definición. Para una feature x se parten los elegibles en quintiles por valor de x (Q_1 a Q_5 ; `pd.qcut(x, 5, duplicates='drop')`: cuando los empates no permiten cinco cortes distintos quedan cuatro, y así ocurre con `n_tiendas_distintas`, `n_categorias_distintas` y `frequency`), se calcula la tasa de riesgo de cada quintil,

$$r_k(x) = \frac{|\{i \in Q_k(x) : B_i(t) = 1\}|}{|Q_k(x)|}, \quad (29)$$

y el poder discriminante es el cociente entre la tasa más alta y la más baja:

$$D(x) = \frac{\max_k r_k(x)}{\min_k r_k(x)} \quad (30)$$

Features. $\text{recency_dias} = \rho_i(t)$; $\text{gap_mediano_compras} = \gamma_i(t)$; $\text{n_tiendas_distintas} =$ tiendas físicas distintas donde el cliente compró hasta t (las compras online no cuentan una tienda; sin ninguna compra física vale 0); $\text{n_categorias_distintas} =$ categorías distintas compradas hasta t ; $\text{frequency} = n_i(t)$, el número de compras; $\text{monetary} = F_i(t)$, la facturación acumulada.

Feature	$D(x)$	Lectura
recency_dias	$41,3\times$	circular: es el término izquierdo de la ecuación (7)
$\text{gap_mediano_compras}$	$9,9\times$	circular: define el umbral $\theta_i(t)$ de la ecuación (6)
$\text{n_tiendas_distintas}$	$1,22\times$	señal genuina, la mejor
$\text{n_categorias_distintas}$	$1,21\times$	señal genuina
frequency	$1,21\times$	señal genuina
monetary	$1,16\times$	señal moderada

Cuadro 4: Poder discriminante por feature sobre los 4.940 elegibles, corte 31/12/2025.

Implementación: entregas/entregable-1/_build/F/recalc_e1.py, líneas C21, sobre `features.client_facts` del corte de referencia.

Valor al corte 31/12/2025: los seis valores de la tabla 4, reproducidos el 15/09/2026.

Por qué se descartan las dos primeras. $B_i(t)$ se calcula con $\rho_i(t)$ y $\gamma_i(t)$: que “predigan” el riesgo es aritmética, no señal. Entrenar un modelo con ellas como features y $B_i(t)$ como target es el *leakage* que advierte Provost y Fawcett. Descontadas, la mejor señal genuina disponible con los seis datasets del Entregable 1 es $\text{n_tiendas_distintas}$ con $1,22\times$. La meta de lift del criterio de éxito 1 de la Parte C ($\geq 1,30\times$ del decil superior contra la línea base de recency, en holdout temporal) es una meta y no una proyección: alcanzarla depende de las señales de reclamos, consultas y devoluciones que llegaron el 08/09 (Entregable 2). La pasada exploratoria del 05/08 reportó además una feature “tendencia” con $4,5\times$; su definición no quedó registrada y no se reproduce, así que no se cita.

10. Anticipación: qué confirma la regla y qué promete el modelo

$B_i(t)$ marca al cliente cuando su recencia *ya superó* su umbral propio: $\rho_i(t) > \theta_i(t)$. Es la misma lógica que el segmento “Inactivos 90d” que Casa Óga usa hoy, con el umbral personalizado por el ritmo de cada cliente. Mejora la precisión de a quién se llama “en riesgo”; no anticipa nada. Ninguna vista del tablero del Entregable 1 anticipa: todas describen el corte.

La anticipación es trabajo del modelo del Entregable 3, con este target:

$$Y_i(T) = \mathbb{K}[E_i(T) = 1 \wedge B_i(T) = 0 \wedge \exists t \in (T, T + 90] : B_i(t) = 1] \quad (31)$$

es decir, entre los clientes elegibles que al corte T todavía no cruzaron su umbral, cuáles lo cruzan dentro de los 90 días siguientes. La condición $E_i(T) = 1$ se agrega en la v2.1 (22/09/2026): un cliente con menos de tres compras no tiene umbral propio y no puede cruzarlo, así que sin esa condición la población del target mezclaría clientes que nunca pueden dar $Y_i(T) = 1$ (sección 14). El modelo puntúa en T la probabilidad de $Y_i(T) = 1$ con señales que se mueven *antes* del cruce: caída de frecuencia y de ticket respecto del propio historial, y desde el 08/09 reclamos, consultas de soporte y devoluciones. Se valida con holdout temporal (entrenar hasta un corte, evaluar sobre los 90 días siguientes), contra la línea base de ordenar por $\rho_i(T)$. El dataset de entrenamiento del Entregable 2 materializa esta definición como una fila por cliente elegible y no en riesgo en cada corte mensual T , del 31/01/2023 al 30/09/2025, con las features calculadas solo con datos de fecha $\leq T$ y el target medido en $(T, T + 90]$; la partición es por corte (entrenamiento hasta 2024, prueba en 2025), nunca aleatoria.

Las “dos semanas de anticipación” del alcance (Parte C, sección 1.2) no son un horizonte de predicción: son el tiempo operativo entre el corte mensual en que se calcula la lista y la salida de la campaña, para que Marketing la reciba antes de que arme el envío del mes. El horizonte de predicción es el de la ecuación (31): 90 días.

11. Experimento propuesto y efecto mínimo detectable

El criterio de éxito 5 de la Parte C y la vista 13 del tablero proponen el mismo diseño: sobre la lista de 800 ya ordenada por $\hat{F}_i(t)$, asignación por ciclo fijo de 20 clientes a tres ramas, 9 reactivación, 9 cuidado y 2 control, lo que da 360 / 360 / 80 por corte, en 3 cortes. Como el ciclo recorre la lista en orden, las tres ramas quedan estratificadas por exposición sin sortear nada.

El control no puede salir del excedente de capacidad: la lista se ordena por exposición y se corta, así que el excedente es por construcción el tramo de menor exposición, y compararlo contra los contactados mide el ordenamiento, no la campaña.

El efecto mínimo detectable (MDE) entre dos ramas de igual tamaño n (acumulado en los 3 cortes) para una tasa base p_0 , con $\alpha = 0,05$ a dos colas y potencia $1 - \beta = 0,80$, es el menor δ que cumple

$$n \geq \frac{\left(z_{1-\alpha/2} \sqrt{2\bar{p}(1-\bar{p})} + z_{1-\beta} \sqrt{p_0(1-p_0) + p_1(1-p_1)} \right)^2}{\delta^2}, \quad p_1 = p_0 + \delta, \quad \bar{p} = \frac{p_0 + p_1}{2} \quad (32)$$

resuelto por bisección sobre δ .

Implementación: pipeline/series.py (potencia_experimento), con p_0 igual a la compra a 7 días global de la ecuación (27), n_por_rama=360, cortes=3; reproducido en entregas/entregable-1/_build/F/recalc_e1.py, líneas C24.

Valor al corte 31/12/2025: $p_0 = 1,21\%$. Entre las dos ramas de mensaje ($n = 1.080$ cada una): MDE = 1,71 puntos porcentuales, 1,4 veces la tasa base; es el número que titula la vista 13. Contra el control ($n = 240$, los 80 por corte), con la misma fórmula generalizada a ramas de tamaño distinto: MDE = 2,95 pp entre una rama de mensaje y el control, y 2,68 pp entre las dos ramas juntas (2.160) y el control (fila C24b del registro; reproducido en recalc_e1.py). El diseño, tal como está, sirve para aprender si el mensaje importa; medir el recupero contra el control con precisión exige un control más grande o más cortes, y el tamaño se acuerda con Marketing antes del piloto (envío 45), que pidió que el control sea una porción menor y no comprometa a los clientes de mayor valor.

12. Limitación: la carga parcial del extracto en 2025

El extracto de transacciones tiene carga parcial en los dos extremos: sube de 44 ventas en enero de 2022 a 893 en diciembre, y baja de 1.390 en enero de 2025 a 255 en diciembre, con el ticket medio estable y las altas de clientes sin caída. Como $\rho_i(t)$ se mide contra el corte, una carga incompleta del cierre de 2025 infla la recencia de todos y con ella $B_i(t)$, $X(t)$ y el riesgo por quintil. Las tres cifras (2.452 en riesgo, ARS 94,9 M/año, 51,8 % en Q5) se mantienen como referencia del tablero y se declaran en revisión hasta que Casa Óga informe el criterio de extracción de cada sistema (pedido del Entregable 2, sección 2.4). Ninguna se repite sin esta salvedad.

13. Supuesto: la exposición no es recupero

$X(t)$ (ecuación (20)) es la facturación anual proyectada de clientes que hoy están en riesgo, calculada con su propio ritmo histórico de gasto. No mide cuánto recuperaría una campaña de retención: recuperar es una afirmación causal (*si contactamos a estos clientes, vuelven a*

comprar tanto como antes) y $X(t)$ no compara contactados contra un grupo de control. Afirmar que Casa Óga “recupera ARS 94,9 M” es una lectura que el dato no sostiene.

Esta distinción ya está declarada en tres lugares del proyecto, y este documento la reafirma como cuarto: en `pipeline/CONTRACT.md` sección 3 (*perdida_esperada* se define como “exposición, no recupero”), en la Parte D sección 2.1 (“Es exposición, no recupero”) y en la misma Parte D, sección 6.1, que deja fuera de alcance de la V1 “la medición de efecto incremental (necesita grupo de control)”. La V2 del proyecto contempla un grupo de control estratificado por exposición sobre la lista ya ordenada (Parte D, sección 6.1, “Plan de evolución”, y sección 11 de este anexo), que es el diseño mínimo para poder hablar de recupero.

Mientras no exista ese grupo de control, cualquier pantalla que muestre $X(t)$ debe rotularlo como *exposición* y no como *ahorro* o *recupero potencial*, y la nota al pie del tablero (Parte D, sección 4.1, [NOTAS FIJAS AL PIE]) tiene que sostener esa distinción en cada corte, no solo en el primero.

14. Supuesto: el proxy de churn no es churn

$B_i(t)$ (ecuación (7)) es una regla de negocio sobre inactividad relativa al ritmo propio de cada cliente. No es una medición de intención de abandono ni la salida de un modelo predictivo con validación: es un umbral fijo, $\max(90, 1,5\gamma_i(t))$, elegido por el equipo y sujeto a la misma discusión que cualquier otro parámetro de negocio.

La regla tiene una consecuencia aritmética directa. La ecuación (7) exige $E_i(t) = 1$: un cliente con menos de 3 compras nunca puede estar en riesgo, sin importar cuánto tiempo pasó desde su última compra. Eso significa que la proporción de clientes elegibles no es pareja entre grupos, y donde no es pareja, comparar tasas de riesgo entre esos grupos mezcla dos efectos: cuánto realmente arriesga cada cliente, y qué fracción del grupo llegó siquiera a poder estar en riesgo.

El caso más claro es el quintil de facturación. La tabla 5 muestra los cinco quintiles con su proporción de elegibles y dos versiones de la tasa de riesgo: sobre el total del quintil (como se reporta en el tablero) y sobre los elegibles del quintil (la que aísla el comportamiento real).

Quintil	Clientes	Elegibles	% elegibles	% riesgo / total	% riesgo / elegibles
Q1	1.196	389	32,5 %	13,3 %	40,9 %
Q2	1.195	1.067	89,3 %	42,5 %	47,6 %
Q3	1.196	1.123	93,9 %	47,8 %	50,9 %
Q4	1.195	1.173	98,2 %	49,7 %	50,6 %
Q5	1.196	1.188	99,3 %	51,8 %	52,1 %

Cuadro 5: Composición de elegibilidad y tasa de riesgo por quintil, corte 31/12/2025. Fuente: `pipeline/features.py:81-84,89`, agrupado por quintil.

$$\text{gradiente}_{\text{total}} = \frac{\% \text{riesgo}_{Q5} / \text{total}}{\% \text{riesgo}_{Q1} / \text{total}} = \frac{51,8}{13,3} = 3,89 \quad (33)$$

$$\text{gradiente}_{\text{elegibles}} = \frac{\% \text{riesgo}_{Q5} / \text{elegibles}}{\% \text{riesgo}_{Q1} / \text{elegibles}} = \frac{52,1}{40,9} = 1,27 \quad (34)$$

Implementación: cálculo propio sobre `pipeline/features.py:81-84,89`. Verificación independiente de las anclas publicadas: `pipeline/build.py:210-211` solo chequea 51,8 % y 13,3 % sobre el total, no el gradiente.

Valor al corte 31/12/2025: $3,89 \times$ midiendo sobre toda la base, $1,27 \times$ midiendo solo entre elegibles.

El gradiente que se muestra en el tablero (Q5 casi cuadruplica a Q1) es en su mayor parte composición: en Q1 solo 1 de cada 3 clientes llegó a las 3 compras que exige la elegibilidad, así que 2 de cada 3 no podían estar en riesgo pase lo que pase; en Q5 esa restricción casi no filtra a nadie (99,3 % elegibles). Entre los clientes que sí pudieron estar en riesgo en ambos quintiles, la diferencia de comportamiento es bastante más chica: $1,27\times$, no $3,89\times$. Cualquier lectura del tipo “los clientes de más valor abandonan cuatro veces más” sobreestima el efecto real en un factor de aproximadamente 3; la lectura defendible es que abandonan proporcionalmente más, una vez que se descuenta que en Q1 la mayoría ni siquiera acumuló historia suficiente para entrar en la medición.